



## 开放获取

编辑

艾登Farajidavar,  
美国纽约理工学院

看过的

Maryam Ravan,

Mohammad Ali Ahmadi-Pajouh, 伊朗Amirkabir理工大学

\*通信潮州牟

mouchaozhou@mail.sdu.edu.cn

2023年4月10日收到2023年6  
月16日公布2023年7月13日

## 引用

孙C, 牟C(2023)基于脑电图的信号处理研究方  
向综述。前 面。 > 17:1203059. doi: 10.3389 /  
fnins.2023.1203059

## 版权

©2023孙和牟。这是一篇根据知识共享署名许可(CC  
BY)条款发布的开放获取文章。在其他论坛上的使用、  
分发或复制是允许的,前提是原作者和版权所有者的  
被记入,并且根据公认的学术惯例引用了在本期刊上  
的原始出版物。不允许不符合这些条款的使用、发行  
或复制。

# 基于脑电图的信号处理研究方向综述

孙丛忠与潮州牟\*

山东大学数学与统计学院, 山东威海

脑电图(EEG)由于其便携性和简单性在脑机接口(BCI)系统中越来越重要。在本文中,我们全面回顾了自2021年以来EEG信号处理技术的研究,重点是预处理,特征提取和分类方法。我们分析了从学术搜索引擎检索到的61篇研究文章,包括CNKI、PubMed、Nature、IEEE Xplore和Science Direct。在预处理方面,我们专注于创新性地提出的预处理方法、通道选择和数据增强。数据增强分为传统方法(滑动窗口、分割和重组以及噪声注入)和深度学习方法[生成对抗网络(GAN)和变异自动编码器(VAE)]。我们也关注深度学习的应用,以及多方法融合的方法,既包括常规算法的融合,也包括常规算法与深度学习之间的融合。我们的分析发现预处理、特征提取和分类方向分别有35项(57.4%)、18项(29.5%)和37项(60.7%)研究。我们发现预处理方法在EEG分类中得到了广泛的应用(占综述论文的96.7%),并在一些研究中进行了对比实验来验证预处理方法。我们还讨论了通道选择和数据增强的采用,并总结了关于数据增强的几个值得一提的事项。此外,深度学习方法在EEG分类中显示出很大的前景,卷积神经网络(cnn)是深度神经网络的主要结构(占深度学习论文的92.3%)。我们总结和分析了几种创新的神经网络,包括cnn和多结构融合。然而,我们也发现了当前深度学习技术在EEG分类中的几个问题和局限性,包括不适当的输入、低跨学科准确性、参数和时间成本之间的不平衡以及缺乏可解释性。最后,我们强调了多方法融合方法的新兴趋势(49.2%的综述论文),并对数据和一些示例进行了分析。我们还提供了对多方法融合的一些挑战的见解。本研究为进一步提高EEG分类性能奠定了基础。

## 关键字

脑电(EEG)、脑机接口(BCI)、预处理、特征提取、分类、深度学习(DL)、多方法融合

## 1. 介绍

脑机接口(Brain-Computer Interface, BCI)是一种通信系统,它允许人类在不依赖周围神经和肌肉的情况下向外界发送信息和命令(Wolpaw等人, 2000)。BCI系统由信号采集、信号处理、控制设备和反馈环节四个主要部分组成。BCI系统中的信号采集技术可分为非侵入式和侵入式两大类。而侵入性方法,如植入

电极直接植入大脑, 已经在一些研究中进行了探索, 但由于潜在的风险和复杂的操作, 它们并不常用。因此, 在许多研究中都采用了非侵入性的方法。非侵入性方法包括功能磁共振成像(fMRI)、功能近红外光谱(fNIRS)、脑磁图(MEG)、脑电图(EEG)和正电子发射断层扫描(PET)。

在上述方法中, EEG信号因其安全、便携、易用、时间分辨率高、成本低等特点而被广泛采用(Singh et al., 2021)。无论在BCI还是临床应用中, EEG信号都是直接反映大脑活动的有用工具(Wolpaw等人, 2000; Michel and Murray, 2012)。例如, EEG-BCI系统的典型应用是通过脑信号控制机械臂, 这不仅对残疾人有很大帮助, 而且对普通人改善生活也有很大帮助(Jeong et al., 2020)。因此, 为了适应BCI的多种应用, 对EEG进行处理和分析是非常重要的。EEG处理通常包括三个主要步骤: 预处理、特征提取和分类。

EEG信号的收集通常使用放置在头皮上的多个电极, 电极放置在头皮的不同位置, 以收集来自不同大脑区域的信号。电极的定位或排列被称为蒙太奇, 蒙太奇有两大类: 双极和参考(Kumar和Bhuvaneshwari, 2012)。前者比较一个电极与其相邻的电极并输出它们的差异作为通道, 而后者选择一个参考电极并将所有其他电极与这个电极进行比较(Sanei and Chambers, 2021)。采集后, 将原始EEG信号表示为形状为 $C \times T$ 的二维张量(多通道1D序列), 其中 $C$ 和 $T$ 分别表示通道数和时间样本。许多数据集采用参考蒙太奇, 因此在这些数据集中, 一个通道对应一个电极。收集到的信号可以认为是许多脑细胞活动的复杂混合物, 导致EEG信号呈现出不同的节奏, 反映了不同的认知状态, 与不同的大脑活动有关。不同的节奏可以根据频率大致分为几个波段, 包括delta (1-4 Hz), theta (4-8 Hz), alpha (8-12 Hz), beta (13-25 Hz)和gamma( $\geq 25$  Hz)(Kumar和Bhuvaneshwari, 2012; Singh et al., 2021年)。此外, EEG信号可以有不同的范式, 涉及不同类型的任务或刺激。常见的范例包括P300 (Bashashati等人, 2007)、运动意象(MI; Cano-Izquierdo等人, 2012)、稳态视觉诱发电位(SSVEP; Wolpaw et al., 2003)等。这些范式通常与特定的大脑活动和信号处理任务有关。例如, 当一个人想象他/她的肢体移动时, EEG信号会发生一些特定的变化, 这种模式被称为MI, 这将与控制设备移动的任务有关。

然而, 为了有效地处理EEG信号, 重要的是要考虑它们的一些固有特征, 包括:

1. 低空间分辨率和低信噪比(SNR)。EEG信号容易受到干扰和伪影。

因此, 信号处理必须解决从异常信号中分离噪声和提取有意义特征的挑战。

2. 维数灾难。EEG在采集过程中具有多个通道, 随着维数的增加, 计算量呈指数级增长。
3. Non-stationariness。EEG信号的统计量随时间变化很快。
4. 缺少大量带标签的训练样本。由于数据采集时对高参与者注意力的要求, 很难获得大量的大脑数据。例如, 在视觉诱发电位(VEP)信号获取过程中, 频繁的视觉刺激会导致视觉疲劳。因此, 许多数据集的样本数量有限。
5. Subject-specificity。个体间EEG信号差异较大, 稳定性和泛化性较差。在特定受试者上训练的模型在新受试者上可能表现不佳(Lashgari等人, 2020)。

此外, 与图像处理和自然语言处理不同, 我们缺乏对大脑生理活动的特定知识。这意味着我们不能直观地理解EEG信号或将我们的先验知识应用于它们。

本文的其余部分组织如下: 在第1节的下一部分, 我们介绍了EEG信号处理的三个步骤, 并总结了之前的一些综述。在第2节中, 我们总结了所提出的方法的相关信息以及论文是如何被选择和评估的。在第3节中, 我们介绍了讨论, 比较了具体的方法, 包括预处理、深度学习和多方法融合。在第4节中, 我们最后展示了我们的结论。

## 1.1. 预处理

在采集EEG后, 需要对数据进行预处理, 以去除无关噪声, 降低计算复杂度。在接下来的文章中, 我们将介绍一些预处理方法。

### 1.1.1. 基本的预处理方法

基本的预处理方法是基于EEG的一些基本特征。这些方法包括滤波、电极定位、删除无用数据、基线校正、重参考、下采样、去除伪影、去除坏段等。这些方法可以很容易地通过EEGLAB工具箱调用, EEGLAB工具箱是一个有用的Matlab工具箱, 可以方便地对EEG进行各种预处理操作(Delorme and Makeig, 2004; Bashashati等人, 2007)。

过滤是最常用的预处理方法之一。EEG信号SNR低, 节律不同; 因此, 带通滤波适用于消除与EEG信号频率不同的噪声, 并从源信号中分离出有用的节奏(Saeidi et al., 2021)。

### 1.1.2. 数据增加

为了解决小数据集的问题，数据增强是一种有效的方法，它既包括滑动窗口、噪声注入、分割和重组等非深度学习方法，也包括生成对抗网络(GAN)和变异自动编码器(VAE;Lashgari等人, 2020;He et al., 2021)。许多模型，尤其是深度学习模型，需要大量的训练数据才能达到较高的分类精度，避免过拟合。然而，由于EEG的固有特性，大量采集EEG数据是困难的。数据增强可以从一个小数据集中生成新的数据，提供足够的训练数据。

在非深度学习方法中，滑动窗口通过在信号上滑动一个窗口来将信号裁剪成几个片段。分段的长度和重叠取决于窗口大小和窗口步长。滑动窗口增加了训练数据的数量，但也消除了长期信息。分割方法可以根据EEG信号的时间特征来分割出特定的时间间隔(Lu et al., 2022)。高斯噪声注入是将高斯分布中的随机矩阵注入到原始数据中，实现数据增强(Okafor et al., 2017)。这些方法直观简单，但由于增广后模型的相似性，可能会加剧模型的过拟合。

GAN及其变体可以通过训练生成网络和判别网络来生成人工数据(Zhang a. et al., 2021)。生成网络接受来自特定分布(如高斯)的随机噪声，并尝试生成与真实数据相似的合成数据，而判别网络则被训练用于对真实数据和合成数据进行分类。这两个网络是對抗性的，经过充分的训练后，生成网络将产生逼真的信号。对于VAE，就像一个普通的自动编码器(将在下面介绍)，编码器将原始数据转换为潜在数据，解码器将潜在数据映射回真实数据。为了生成新的数据，VAE从学习到的潜在空间中随机抽取点，然后将这些点传递给解码器网络，由解码器网络重构成新的样本。GAN和VAE都间接产生新样本。

### 1.1.3. 通道选择

在采集过程中，每个电极记录一个通道的数据。因此原始EEG具有C通道，这就是EEG的多维性。不同的通道对应着大脑的不同区域。对于特定的任务，一些通道可能包含与任务无关或冗余的信息(Liu et al., 2016)，这增加了数据大小和时间成本，并会对BCI的性能产生负面影响(Asensio-Cubero et al., 2013)。通道选择是一种选择任务相关区域中最显著的通道作为最优通道的方法，从而提高性能和效率。然而，多通道EEG数据包含复杂的通道相关性，而不是简单的邻接关系(Cona et al., 2009;Hamed et al., 2016)。因此，我们应该根据通道的特征(如相关性、电极距离和任务特征)寻求选择标准

，以选择最大限度保留信号特征的通道。

### 1.1.4. 降维

EEG信号是多维信号。与传统的一维信号相比，EEG处理具有较高的计算复杂度。因此，我们通常需要根据EEG的结构施加相应的约束假设，并对特征信号进行降维，以进一步提高特征信号的提取效果和分类鲁棒性。

很多算法都可以降低维度。例如，主成分分析(principal Component Analysis, PCA)可以将EEG信号分解成方差最大的线性不相关分量。在重建EEG信号之前，可以通过PCA分离冗余成分，如来自眼睛和肌肉的干扰(Liu and Yao, 2006)。独立成分分析(ICA)基于数据特征将EEG信号中的伪像作为独立分量分离出来(Saeidi et al., 2021)。Geng等(2022)提出预处理可以通过ICA将复杂的混合信号分解为独立的信号，实现P300信号与噪声的分离。然而，由于ICA算法没有经过训练来学习噪声信号的特征，一些有价值的信号可能会被作为噪声去除，造成一些大脑活动信息的丢失。利用小波变换(Wavelet Transform, WT)提取EEG的特征，然后通过ICA-WT滤波，有效地消除噪声伪像，从而有效地提高了不同被试EEG的精度(Ayoobi and Sadeghian, 2022)。Ayoobi and Sadeghian(2022)也研究了自动编码器(AutoEncoder, AE)进行预处理，编码器将输入原始数据的信息提取到一个小的潜在空间中，然后对潜在数据进行解码，重建数据集。由于潜变量携带原始信号的信息，但维度更少，我们可以使用潜变量作为后续步骤的输入。

## 1.2. 特征提取

特征提取一般指从信号中提取隐藏的大脑信息特征。接下来，我们将介绍一些特征提取的方法，既包括常规算法(非深度学习)，也包括深度学习算法。

### 1.2.1. 用常规算法进行特征提取

特征提取采用的传统算法包括公共空间模式(CSP)、傅里叶变换(FT)、功率谱密度(PSD)、小波变换(WT)、小波包分解(WPD)、经验模态分解(EMD)、自回归(AR)和Hjorth参数等(Wolpaw et al., 2003;Kim等人, 2018年;托雷斯等人, 2020年)。

公共空间模式(CSP)是一种用于二值分类任务的空间域滤波算法。CSP提取多通道EEG信号的每一类空间分布分量，寻求最佳投影方向，使一类方差最大，另一类方差最小(孟)



Et al., 2022)。由于CSP最大化了EEG之间的差异, 因此更能挖掘EEG的特征。但是, 由于对EEG信号进行多通道分析需要大量的电极, 因此电极的数量还需要进一步优化。CSP也有许多变体, 如公共空间光谱图(CSSP), 滤波器组CSP (FBCSP) 等(Park 等人, 2018; Maruyama et al., 2020; Kumar et al., 2021)。

EEG信号表现出不同的频带, 每个频带都与不同的大脑活动有关。因此, 从频域和时频域分析EEG是一种常用的方法。傅里叶变换(FT), 特别是快速傅里叶变换(FFT)是频率分析的基本工具。它可以将平稳信号变换到频域, 提取频率特征。功率谱密度(PSD)是信号自相关函数的FT, 揭示了功率(能量)在不同频率上的分布。然而, FT和PSD只能分析整个系列的频率内容。要分析频率随时间的变化, 时频分析方法是必要的。短时傅里叶变换(short - time Fourier Transform, STFT)先将信号分割成短时间间隔, 然后进行傅里叶变换分析频率方差。小波变换(WT)是STFT的改进方法, 适用于分析EEG信号等非平稳信号(AI-Fahoum and Al-Fraihat, 2014)。小波包分解(Wavelet Packet Decomposition, WPD)是WT的一种改进, 它进一步分解了高频子带, 提供了更好的频率分辨率。在进行时频分析之后, 信号的形状变成了 $F \times T \times C$ , 其中 $F$ 代表频率分辨率。

此外, 自回归(AR)是一种常用的时间序列预测方法。AR假设时间序列的当前值线性依赖于其过去值(Saeidi等, 2021)。另一种用于分析非平稳EEG信号的技术是经验模态分解(EMD)。EMD是一种非线性方法, 它将信号分解为其固有振荡模态(El-Kafrawy et al., 2014)。该方法已被用于研究EEG的时频特性。最后, Hjorth参数是用于提取EEG信号信息的统计特征(Du et al., 2021)。三个Hjorth参数是Activity、Mobility和Complexity。活跃性衡量信号的能量, 移动性衡量信号的频率含量, 复杂性反映信号的非线性。

## 1.2.2. 通过深度学习自动提取特征

CSP、PSD等传统特征提取算法存在局限性。例如, 特征提取和分类是分开进行的, 在特征提取过程中需要手工添加很多经验或先验知识。相比之下, 深度学习算法利用由许多隐藏层组成的深度架构, 利用大量训练参数和数据自动提取EEG信号的时空特征(Aellen et al., 2021)。深度学习的判别模式在空间检测中的位置是无关紧要的, 这往往导致神经网络的表现优于传统的机器学习算法。深

度学习算法能够学习有用的特征, 捕捉EEG信号的底层结构, 而不需要显式的特征提取。此外, 深度学习方法有可能克服传统特征提取方法的局限性, 使EEG信号的分类更加准确。

## 1.3. 分类算法

机器学习的一般任务可以分为两类: 回归和分类。有几篇采用回归方法的新颖论文, 如Jeong et al.(2020)采用深度学习跟踪机器人手臂的运动。但在EEG的研究中, 由于任务的标签和处理的输出通常是分类变量, 因此大多数研究集中在分类上。开发性能更高、鲁棒性更强的分类算法是EEG研究的重点。分类算法的选择对决定系统的性能起着至关重要的作用。

### 1.3.1. 常规分类算法

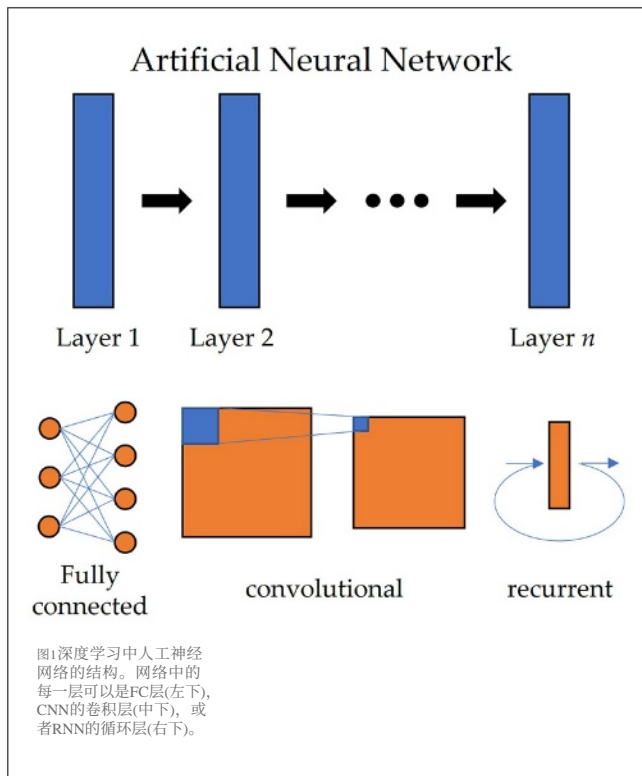
传统的脑机接口分类算法包括支持向量机(SVM); Li et al., 2018), 线性判别分析(LDA; Vidaurre et al., 2011)和 $k$ -最近邻(KNN; Tang et al., 2019)。SVM可以用于线性可分数据, 通过优化算法找到最优超平面。对于线性不可分的问题, 可以使用核函数将数据转换到更高维的空间。LDA是一种简单的线性分类器, 它将所有样本投影到一条线上, 以最大化类间距离并最小化类内方差。KNN是一种分类方法, 它计算与新样本距离最小的 $k$ 个最近样本的类数。

SVM和LDA是目前比较流行的算法, 具有较好的性能, 但SVM计算复杂, LDA需要线性可分性。KNN简单易用, 但泛化能力较弱。

### 1.3.2. 深度学习算法

深度学习算法已被证明在从高维数据中提取特征方面是有效的。它们对于处理通常是高维和复杂的EEG信号特别有用。深度学习使用人工神经网络(Artificial Neural Networks, ANN)处理数据, 可以自动学习与任务相关的特征, 并且可以很好地泛化到不同的任务中。ANN的结构如图1的顶部所示。应用于EEG信号处理的常见深度学习算法和人工神经网络包括多层感知器(MLP)、卷积神经网络(CNN; Mane 等人, 2020), 循环神经网络(RNN; Luo et al., 2018)等。

最简单的深度学习算法是多层感知器(MLP)。MLP是由全连接(FC)层(在某些论文中也称为密集层或线性层)构成的网络, 其中线性变换和后续变换



非线性激活函数依次使用。设  $\mathbf{x} \in \mathbb{R}^m$  为输入, 单个FC层的输出  $\mathbf{y} \in \mathbb{R}^n$  由式计算

$$\mathbf{y} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}); \quad (1)$$

其中  $\mathbf{W} \in \mathbb{R}^{m \times n}$ ,  $\mathbf{b} \in \mathbb{R}^n$ ,  $\sigma$  分别为权重矩阵、偏置和激活函数 (Zhang A. et al., 2021)。图1的左下角展示了FC层的一个示例。目前很少单独使用MLP, 但FC通常与其他网络结合使用, 作为最后一层对特征进行分类。

卷积神经网络(CNN)是一种广泛应用于EEG信号处理的深度学习算法。CNN采用卷积运算从数据中自动提取特征。CNN由多个卷积层组成, 它们接受二维图像或三维多通道图像作为输入, 并对其进行卷积运算。对于给定的输入  $\mathbf{X} \in \mathbb{R}^c \times m \times n$ , 卷积层给出输出  $\mathbf{Y} \in \mathbb{R}^d \times m' \times n'$  by

$$Y_{d,i,j} = \sum_{p=-\delta_1}^{\delta_1} \sum_{q=-\delta_2}^{\delta_2} \sum_{r=1}^c \mathbf{K}_{d,r,p,q} \mathbf{X}_{r,i+p,j+q}; \quad (2)$$

其中  $c$  和  $d$  分别表示输入通道和输出通道;  $\mathbf{K} \in \mathbb{R}^d \times c \times (2\delta_1 + 1) \times (2\delta_2 + 1)$  是CNN的核, 也是参数 (Zhang A. et al., 2021)。图1的底部中间显示了卷积层的图。由于  $c$  和  $d$  是由层决定的, 所以核  $\mathbf{K}$  的形状往往被缩短为  $(2\delta_1 + 1) \times (2\delta_2 + 1)$ , 卷积层的操作实际上是一个空间滤波器, 但它的参数可以由反向传播算法自动更新。此外, 不同大小的核可以用于不同的任务。当输入张量的大小为  $C \times T$  时, 如原始EEG信号, 如果我们把核的大小设置为  $1 \times n$

, 它将沿着时间维度提取特征; 如果  $m \times 1$ , 它将寻求不同通道的相关性。

大量的CNN结构已被应用于EEG处理, 如残差网络 (ResNet) (He et al., 2016) 和 ConvNet (Azizpour et al., 2016)。脑电图特异性神经网络也被提出, 如EEGNet。EEGNet是一种紧凑的CNN, 只有三个卷积层, 它采用了深度卷积层和可分离卷积层两种特殊结构, 以减少参数数量和计算成本 (Lawhern et al., 2018)。脑电图网络 (EEGNet) 于2018年被提出, 并被证明对不同的EEG范式具有更强的鲁棒性、更紧凑性和更少的数据密集型, 因此在EEG处理中得到了广泛的应用。

递归神经网络(RNN)是另一种深度学习算法, 已用于EEG信号处理。RNN在传统的MLP中附加一个隐藏状态, 并将隐藏状态传递到下一个单元, 适合于提取时间序列模型的长期关系。EEG作为一种上下文敏感序列, 也适合使用RNN提取时序特征。RNN的循环单元接受序列  $\mathbf{x} \in \mathbb{R}^T$  作为输入, 并将计算隐藏状态  $\mathbf{h}$  和输出  $\mathbf{y}$  by

$$\begin{cases} \mathbf{h}_t = \sigma(\mathbf{W}_1 \mathbf{x}_t + \mathbf{W}_2 \mathbf{h}_{t-1} + \mathbf{b}_2); \\ \mathbf{y}_t = \mathbf{W}_3 \mathbf{h}_t + \mathbf{b}_2; \end{cases} \quad (3)$$

其中  $\mathbf{W}_1$ ,  $\mathbf{W}_2$ ,  $\mathbf{W}_3$  为权重矩阵,  $\mathbf{b}_1$ ,  $\mathbf{b}_2$  为偏置,  $\sigma$  为激活函数。递归层的结构如图1右下角所示。长短期记忆(LSTM)网络 (Wang et al., 2018) 和门控循环单元 (GRU; Nakagome等人, 2020) 是RNN的两种流行变体。通过在传统RNN中加入多个门单元, 继承了RNN的优点, 使序列数据分析更加准确。

批归一化 (Batch Normalization, BN)、退出和注意机制也被广泛使用。在小批量前馈步骤中, 通过BN的数据将减去均值并除以方差, 转换为零均值和单位方差 (Zhang A. et al., 2021)。通常在激活函数之前使用BN, 以提高激活函数的区别。Dropout是一种使网络单元以概率  $p$  停止以避免过拟合的方法, 仅在训练时使用 (Zhang A. et al., 2021)。注意力机制模拟了我们大脑的注意力功能, 使重要信息突出。注意机制不是一个单一的算法, 而是包括传统方法和基于cnn的方法在内的一组方法。

此外, 迁移学习 (Transfer Learning, TL) 算法用从其他领域转移的数据补充有限的训练数据, 以提高系统的可移植性, 在保证准确性的同时解决训练时间长的问题 (Zhang等, 2020)。TL利用两个任务之间的相似性, 将从源网络中学到的知识转移到目标网络中, 以增强模型。面对小数据集, TL已经成为提高性能的有效方法。

## 1.4. 研究问题和贡献

在之前的研究中, Alzahab等人(2021)全面总结了2015年至2020年间基于脑电图的BCI系统中使用的混合深度学习算法,并比较了它们的准确性。然而,他们也强调缺乏关于预处理对脑电图分类准确性影响的证据。Vallabhaneni等人(2021)调查了在不同应用中使用深度学习解码脑电图信号的文章,并概述了一些现有的深度学习问题。Chen和Xie(2019)建议根据脑电图的特征和大小选择数据处理方法。他等人(2021)回顾了数据增强在脑电中的应用,发现它可以提高分类性能,克服小规模数据集的挑战。Saeidi et al.(2021)根据不同的任务系统回顾了基于机器学习的脑电图解码方法,得出CNN、SVM和WT是最有效的深度学习、传统机器学习和特征提取方法。这些研究为脑机接口脑电的发展做出了贡献,也凸显了该领域存在的挑战。

本文分析了2021年以来的最新研究,并将其与2020年之前的综述和文章进行了比较。之所以选择2021年后的文章,是因为已经有大量的综述聚焦于2020年之前的文章,我们想总结一下最新的发展。根据我们所回顾的文章,我们概述了基于脑电图的BCI信号的研究前景和新兴趋势。我们重点回答以下研究问题:当前BCI信号处理的研究课题是什么?我们如何评估BCI性能并加以改进?这一领域正在探索哪些创新方法?我们还评估了不同方法的优势和局限性。我们的主要贡献如下:

1. 总结了BCI系统中基于脑电图的各种信号处理方法及主要研究趋势。我们还提出了潜在问题的解决方案。
2. 我们试图寻求有效、合理、有用的BCI性能指标。
3. 我们证实了预处理对性能的有效性。
4. 从不同方面讨论了深度学习和多方法融合研究,总结了存在的几个问题。

## 2. 搜索方法及复习表

### 2.1. 搜索方法

选择研究文章于2022年6月31日进行综述。进行了以下数据库的研究:CNKI、PubMed、Nature、IEEE Xplore和Science Direct。搜索涵盖了2021年至2022年期间发表的研究。使用以下查询术语:(“脑机接口”或“脑机接口”或“BCI”)和(“脑电图”或“脑电图”)和(“预处理”或“特征提取”或“分类”)。这一搜索产生了61篇研究论文,如图2所示。

## 2.2. 综述论文

通过对基于脑电的BCI信号处理相关文献的收集和总结,对各种新型脑电信号处理方法进行了梳理,并分析了其性能特点。

由于所有评审论文的表格太大,我们只提供本文评审的论文列表。关于每篇论文的方向和表现的详细表格可以在[补充材料中找到](#)。以下审阅的论文按发表日期升序排列(Aellen et al., 2021;Asheri et al., 2021;Ashwini和Nagaraj,

2021;awis等人, 2021年;蔡等, 2021年;Dagdevir和Tokmakci,

2021;德维努托和梅兹纳, 2021年;杜等人, 2021年;范等,

2021年,2022年;费拉库蒂等人, 2021年;Gao N.等人, 2021;高智等, 2021;Gaur等, 2021;拉什加里等人, 2021年;廉等人, 2021年;刘、金, 2021;刘、杨, 2021;刘等人, 2021;齐等, 2021;拉希德等人, 2021年;孙等人, 2021年;瓦尔塞希和菲鲁扎巴迪, 2021年;维加等人, 2021年;沃龙索瓦等人, 2021年;瓦希德和塔夫雷希, 2021年;王、全, 2021年;徐畅等, 2021;徐峰等, 2021;尹等, 2021;张凯等, 2021;张燕等, 2021;阿尔加尼等, 2022;阿里等, 2022;Asadzadeh等, 2022;阿尤比和萨德吉安, 2022;巴格奇和巴图拉, 2022;昌等人, 2022;陈杰等, 2022;陈霖等, 2022;崔等, 2022;耿等, 2022;Islam等,

2022;贾等人, 2022;金等, 2022;Ko等, 2022;李、孙,

2022;李宏等, 2022;林等, 2022;李强等, 2022;陆等,

2022;马等人, 2022;马蒂奥利等, 2022;孟等, 2022;裴等, 2022;宋等, 2022;苏海米等, 2022;唐等, 2022;徐等, 2022;应等, 2022;赵等, 2022)。

## 3. 结果与讨论

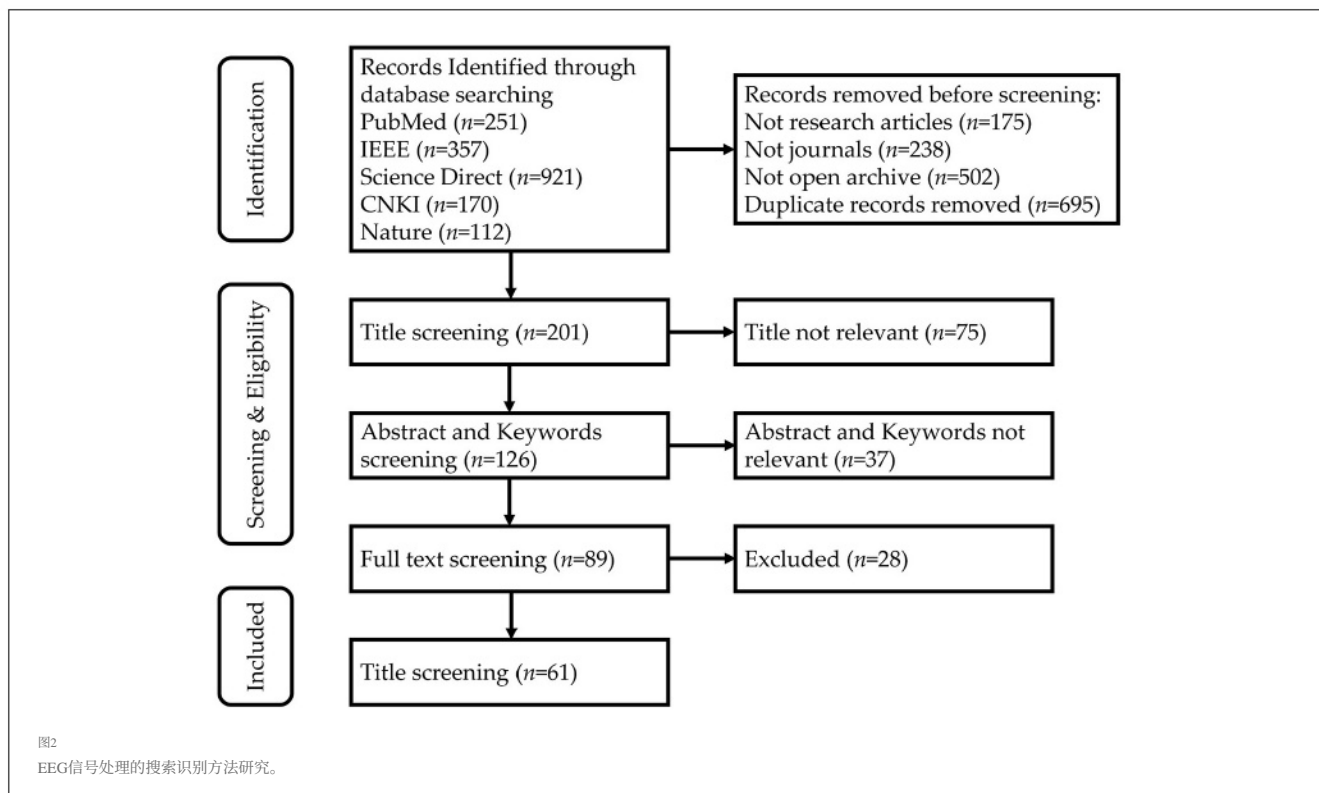
基于EEG信号的BCI系统对人脑发出的指令进行分析。EEG的处理和分类决定了BCI系统的性能。在EEG信号处理的研究中,出现了几个问题,包括:

1. 当前EEG处理技术的发展趋势是什么?
2. 如何选择适合EEG信号特性的处理方法?
3. 如何正确应用深度学习算法提升性能?
4. 为什么我们需要多方法融合,它们有效吗?

考虑到EEG的特点,对EEG进行处理的目的是寻找一种可行的方法来融合信号模式,寻求高性能和强适用性的处理方法。目前,对EEG进行预处理、特征提取和分类的算法很多,各有优缺点。因此,应根据具体情况选择合适的方法。在本文中,我们根据第1节介绍的类别对算法进行分类。下面,我们将讨论综述研究的方向和数量。

在预处理方面,通过增加数据样本和识别有效数据,可以获得更好的信号特征,减少计算成本。通过对61篇论文的研究,我们发现





预处理研究数量为35项(57.4%)。这表明预处理是寻求EEG信号更突出特征和实现更高性能的重要步骤。在特征提取方面,由于深度学习对EEG信号具有很强的自动特征提取学习能力,特征提取往往由深度学习算法自动完成。因此特征提取研究的数量只有18个(29.5%)。分类算法数量为37种(60.7%),说明分类算法的创新仍然是提高BCI性能的主要方法。因此,它是当前EEG处理研究的重点和热点。这三个方向的研究数量如图3所示。

### 3.1. EEG指标

在EEG分类中,分类器的性能采用各种指标来衡量。准确率(ACC)仍然是各论文中使用最广泛的指标,因为它提供了一种对分类性能的直观衡量。然而,其他几个指标,如混淆矩阵(Algarni et al., 2022)和kappa (Lian et al., 2021),也被普遍使用。混淆矩阵比较的是 $n \times n$ 矩阵中预测和实际标签的数量。另一方面,kappa衡量分类的一致性,并在多个研究中被用于衡量性能改进。

虽然准确性是主要指标,但16篇论文还比较了参数数、信息翻译率(Information translational Rate, ITR)和计算时间等其他因素。参数数用于衡量一个模型的复杂性,尤其是神经网络。ITR和计算时间反映了分类的速度,在许多研究中是至关重要的因素。值得注意的是,

有6项研究提高了ITR, Zhang K. et al.(2021)的最大ITR达到了170.67 bit/min。7项研究实现了时间成本的降低,反映了计算效率的重要性。

考虑到EEG信号的受试者特异性,研究人员还研究了受试者依赖(受试者内)和受试者独立(跨受试者)准确度之间的差异。独立于受试者的任务涉及在新个体上测试模型,这些新个体的数据没有包含在训练数据中,而受试者依赖的任务则是在相同个体数据的不同段上测试。Singh等人(2021)强调了独立于受试者的任务的重要性——它们在设计即插即用的免校准BCI设备中发挥着至关重要的作用。虽然许多研究报告了很高的受试者内精度,在一些情况下可以超过90%,但跨受试者的精度仍然较低(大多数在50%左右;Lashgari等人, 2021;范等人, 2022)。提高跨主体准确率成为了一个重要的方向。

### 3.2. 预处理

在35篇关于预处理的研究中,创新的预处理方法包括通道选择(10篇论文, 28.6%)、降维(11篇论文, 31.4%)、数据增强(16篇论文, 45.7%)等,如图4所示。降维是降低计算复杂度的常用方法,但在应用降维的研究中,只有大约一半的研究有创新方法。虽然通道选择和滑动窗口也被广泛使用,但许多论文提出了新的通道选择或滑动窗口方法。

根据Alzahab等人(2021)的研究,在2015年至2020年的混合深度学习(hDL)研究中,21.28%的研究没有进行

## Numbers of Reviewed Paper Directions

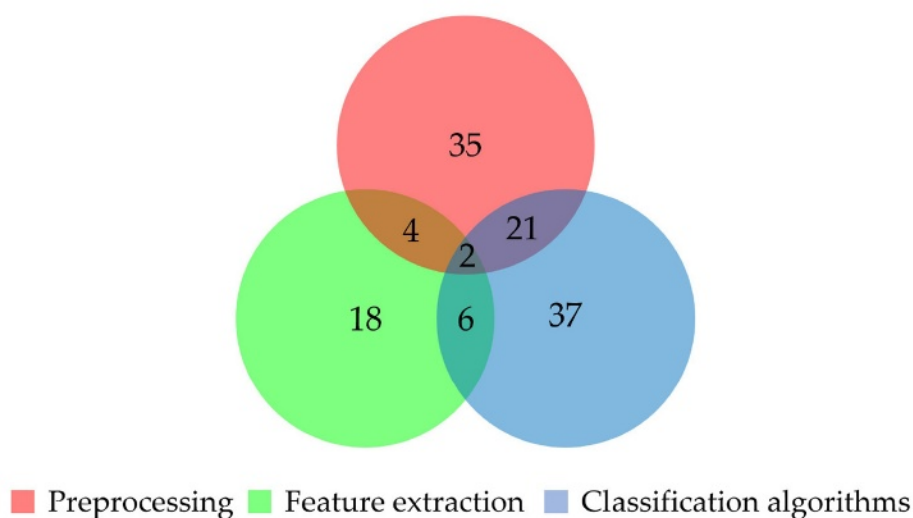


图3

不同方向EEG处理的数量。预处理(P)、特征提取(F)和分类算法(C)论文的数量分别为35、18和37篇。同时关于P和F、同时关于P和C、同时关于F和C(都包括中间的两篇论文)的论文数分别为4、21和6。有两篇论文集中在这三个方向上。

## Numbers of Preprocessing Methods




图4

预处理方法比较。蓝色条形图表示涉及一种方法的论文数量，橙色条形图表示改进或提出的新方法。

应用任何预处理步骤，61.7%应用了基本的预处理，如带通滤波，17.02%应用了更高级的预处理方法，如ICA和PCA。我们的研究表明，自2021年以来，应用hDL的研究中分别有24项(100%)和15项(62.5%)进行了预处理和高级预处理方法。此外，Alzahab等人(2021)也指出，由于他们所查阅的论文都没有对预处理前后的性能进行比较，因此无法确定预处理是否能提高准确性。

但是，我们发现，2021年以来的几篇论文都对预处理进行了对比实验，并明确得出了适当的预处理方法可以提高精度性能的结论。例如，Lashgari等人(2021)表明，通过选择最优信道(ACC = 81.73%)，相比于没有信道(ACC = 71.47%)，CNN和GRU混合算法的准确率提高了10.26%。因此，这已经证明了适当的预处理方法可以提高整个处理任务的性能。



在下一节中，我们将讨论预处理研究的几个方向，包括创新的预处理方法、信道选择和数据增强(包括滑动窗口、分割和重组、噪声注入、GAN和VAE)。

### 3.2.1. 创新的预处理方法

通过预处理提高分类器性能的研究数量显著增加，61篇论文中有60篇(98.4%)包含预处理，其中35篇(57.4%)通过创新的预处理方法提高性能。

许多创新的预处理方法都与深度学习网络的结构有关。例如，Liu和Yang(2021)以及Bagchi和Bathula(2022)都将原始信号转换为三维张量，如图5所示。前者简单地粗略表示电极在矩阵中的位置，对没有电极的细胞进行零填充，而后者采用方位角等距投影(Azimuthal equidistance Projection, AEP，一种将球体投影到平面上的方法)将三维电极的分布转换为二维热图图像，并保持电极的相对距离。经过AEP和插值后，EEG信号成为一个具有大量二维热力学图像的视频流，可以通过ConvTransformer进行分析，这将在3.3.1节中讨论。

自动编码器通过将原始EEG转换成一个小向量来提取其特征并降低其维数。在Ayoobi和Sadeghian(2022)中，对LSTM-AutoEncoder进行无监督训练，并将潜在变量用作特征提取算法的输入。这表明AE可以提取有效的特征，并大大降低输入信号的大小。

### 3.2.2. 选择最优通道

在专注于预处理的35篇论文中，有12篇(34.3%)讨论了通道选择，这表明选择最优通道是提高分类性能的一个有希望的方向。在Liu和Jin(2021)的研究中，使用提出的双谱和基于欧氏距离的通道选择(BECS)算法进行通道选择，35名受试者中有18名的分类准确率显著提高(配对 $t$ 检验， $p < 0.05$ )。准确率和ITR分别提高了7.38%和18.4%。然而，10名被试的表现没有显著变化，7名被试的准确率出现下降。他们还假设，通过对所有引线进行排序，并用模糊系统进行融合，就有可能自动确定是否选择通道，从而避免成绩下降。Yin et al.(2021)使用投票的方法来选择最优通道，与传统的FBCSP算法相比，不仅显著提高了分类率( $p < 0.01$ )，而且降低了计算复杂度。

### 3.2.3. 数据增加

在本研究中，我们回顾了22项应用数据增强技术来增强EEG信号处理的研究。其中，我们发现16篇研究采用了创新

的数据增强方法，可分为滑动窗口(10篇，45.5%)、分割和重组(4篇，18.2%)、高斯噪声(1篇，4.6%)、GAN(4篇，18.2%)和VAE(1篇，4.6%)。由于一项研究可能会使用多种数据增强方法，因此总比例超过100%。

许多研究采用了传统的数据增强方法，包括滑动窗口和分割重组。例如，Gaur et al.(2021)采用基于滑动窗口的SW-Mode技术来减少受试者之间的差异，在卒中患者数据集中取得了比现有最好技术更优越的性能( $ACC = 80\%$ ， $p < 0.05$ )。在Lian et al.(2021)的另一项研究中，时间窗被划分为1 s，以增加训练样本数量并满足CNN的要求，增强稳定性并减少个体差异的影响( $kappa = 0.78$ )。类似地，在Islam等人(2022)的一项研究中，数据集被分为三个不同的短决策窗口(1、2、3 s)，他们得出的结论是，选择一个较短的决策窗口可以降低计算复杂度，最大限度地减少单一决策使用额外功能，并使系统更快。在Ayoobi和Sadeghian(2022)的另一项研究中，预处理步骤涉及比较不同时间窗口的片段，作者发现，通过剪切成短片段来匹配自注意力机制，平均分类准确率提高了13.9%，计算复杂性降低了。

GAN可以模拟数据集中的样本，生成新的EEG样本，以提高准确率(Lashgari et al., 2021)。然而，训练稳定性差是一个问题。例如，Song等人(2022)使用GAN的一种变体——辅助分类器GAN (ACGAN)生成新数据来扩展训练数据集，满足了深度学习的要求，准确率提高了1.7%。

研究还探索了扩散模型。扩散模型(DM)作为GAN的最新替代品，可以生成高质量的图像，在AI绘画中有着广泛的应用。因此，我们认为扩散模型也可以产生相似的EEG信号。例如，Duan et al.(2023)利用扩散去除伪影，提高跨主体精度。然而，关于扩散模型在EEG生成中的应用的文献很少，还需要进一步的研究。

然而，数据增强也有一定的局限性，在其应用中必须考虑到这些局限性。这里我们列出三个主要因素。

首先，通过数据增强产生过多的数据是不合适的。超过一定数量后，生成更多的数据进入训练数据集，只会增加训练时间，不会提高模型的泛化能力。例如，在Lashgari等人(2021)的研究中，在BCI Competition IV数据集2a上应用15倍的数据增强后，模型达到了最好的准确率(93.6%)。如果采用20倍的增强，准确率反而会下降。

其次，合成EEG与图像的一个主要区别是EEG不能直接解释。虽然gan和其他基于深度学习的生成器在合成图像生成方面取得了成功，但解释真实图像和合成图像之间的差异是一项挑战

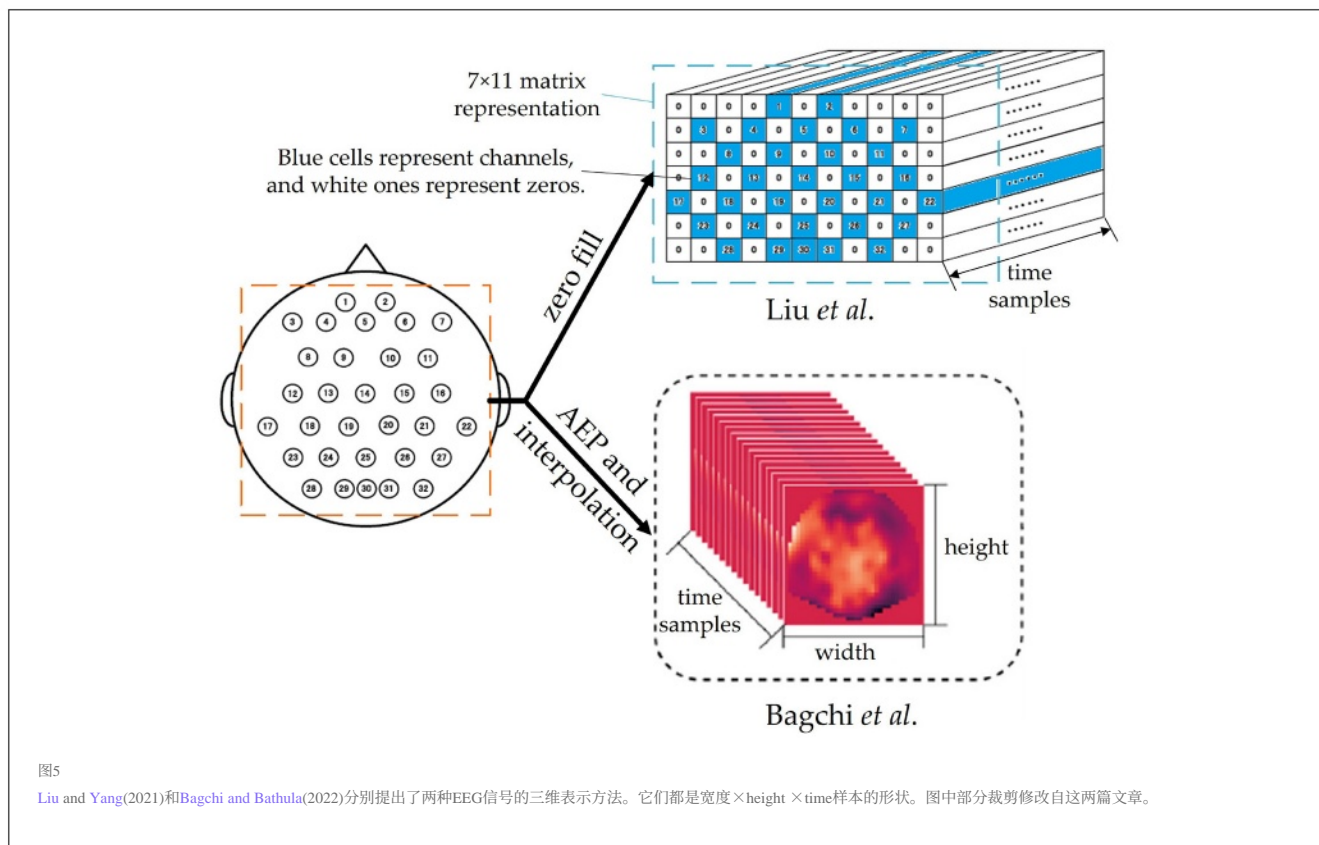


图5

Liu and Yang(2021)和Bagchi and Bathula(2022)分别提出了两种EEG信号的三维表示方法。它们都是宽度×height×time样本的形状。图中部分裁剪修改自这两篇文章。

EEG信号。滑动窗口和噪声注入方法确保增强数据与真实EEG信号相似，但gan和变分自编码器(VAEs)的透明度较低，导致新的“黑匣子”。

第三，在给定的情况下选择合适的数据增强方法至关重要，因为不同的方法既有优点也有缺点。例如，滑动窗口和分割重组可以直接对输入空间中的数据进行增强，既直观又计算成本低(He et al., 2021)。但是，这种方法也增加了训练数据的相似性，可能会造成过拟合，降低模型的分类精度。

### 3.3. 深度学习算法

如1.3.2节所述，CNN可以通过设置不同大小的核提取时空核，RNN可以提取长期时间核。在我们的研究中，我们发现大多数关于深度学习的论文都使用CNN单独或与其他结构一起提取特征，并使用FC作为最后一层将提取的特征分类到给定的类别中。一些论文还在CNN之后添加了一个RNN层。此外，批量归一化(BN)和dropout层被广泛应用，以避免过拟合。

在我们的研究中，有28篇论文使用了深度学习算法，其中大部分依赖于cnn(26篇，92.9%)，其次是rnn(8篇，28.6%)和MLP(1篇，3.6%)。大多数CNN和RNN算法都提出

了创新的方法。值得注意的是，自2021年以来，基于CNN的算法在61篇被评审的论文中占42.6%，这表明CNN是EEG信号处理的主流分类和深度学习方法。在审阅的28篇DL论文中，20篇研究使用时域信号作为输入，而6篇研究使用时频域信号。不同方法或结构的数量如图6所示。由于一些研究使用了多种方法，每个部门的总和可能会超过总数。

我们的研究表明，深度学习的流行和cnn作为一种分类算法的流行可以归因于三个因素：

1. DL不仅可以应用于空间域和时间域，还可以应用于频率域和时频域。cnn主要用于提取空间特征，而rnn可以提取比cnn更长时间的特征。
2. 分类精度高度依赖于训练数据量，有限的训练数据往往导致精度低。近年来，数据增强和迁移学习在一定程度上解决了这个问题。数据增强通过应用各种预处理技术来扩展数据量，而迁移学习利用来自其他领域的知识和经验，以较小的数据集训练模型。迁移学习缩短了训练时间，受个体差异的影响较小。
3. DL算法通过共享参数或构建符合EEG特征的浅层神经网络，减少了计算量，提高了BCI性能。




图6

综述论文中使用的不同深度学习方法的数量。橙色扇区代表MLP，有一篇论文。特种CNN包括图形CNN等。

### 3.3.1. CNN的应用与创新

当输入形状为 $C \times T$ 时，cnn能够分别使用1个 $\times M$ 和 $N$ 个 $\times 1$ 核提取空间和短期时间特征。对cnn的研究可以分为三类:(1)改进已提出的网络;(2)修改来自其他领域的网络;(3)提出创新的网络结构。

第一，改进所提出的网络。如1.3.2节所述，EEGNet是根据EEG信号的特点专门设计的网络(Lawhern et al., 2018)。为了提高性能，对EEGNet进行了各种修改。例如，Li H. et al.(2022)增加了一个FC层来连接三个卷积层的输出，以聚合不同的特征，提高EEGNet的精度。Vega等人(2021)在EEGNet之后增加了一个模糊神经块(Fuzzy Neural Block, FNB)，并证明FNB可以略微提高主题依赖分类的准确性。

第二，适应来自其他领域的网络。研究人员将图像处理和计算机视觉领域的创新结构应用于EEG信号处理。例如，Bagchi和Bathula(2022)修改了最初用于视频处理的ConvTransformer网络，以处理EEG信号，并在几种方法中达到最高的精度。在这里，原始的E

EG信号被预处理成视频流，作为ConvTransformer的输入，类似于视频处理中使用的方法。然而，ConvTransformer模型由于参数较多，计算复杂度较大。此外，Lin et al.(2022)将成像处理领域的空间注意机制(Spatial Attention Mechanism, SAM)插入到他们的网络中，提取EEG信号的显著频率。

第三，提出一种创新的网络结构。与传统的2D-CNN相比，深度学习的方法多种多样。Mattioli et al.(2022)提出了一种1D CNN，这是一种特殊的卷积层，它接受形状为 $T \times C$ 的输入，并使用 $Q$ 个 $\times C$ -shaped核对输入进行处理，从而对第二维空间进行压缩，输出形状为 $T \times O$ 的张量，其中 $O$ 为输出通道数。通过顺序构建多个一维cnn，在降低计算成本的同时达到较高的精度。Lashgari et al.(2021)提出了一种相对简单的网络，使用共享参数卷积层作为滑动窗口来处理信号，而不需要任何常规的预处理方法。然后，他们使用CNN和自关注机制来提取特征，并使用FC层进行分类。与其他最先进的网络相比，该网络取得了最高的准确率，主要是因为它放弃了之前的预处理和手动超参数选择等方法，允许所有参数自动训练和更新。



也有深度学习研究聚焦于脑电图脑机接口的特定应用。例如, [Vorontsova等人\(2021\)](#)为了开发一种BCI, 让有交流障碍的人控制设备的运动, 使用ResNet和GRU设计了一个简单的网络, 但没有最后一个FC层, 用于在无声讲话时将EEG信号分类为正确的单词。他们假设一个主题上的较小数据集(即依赖于主题的数据集)将有助于更高的准确性, 这在他们的实验结果中得到了证明。同样, [Vega等人\(2021\)](#)将基于p300的EEG信号应用于智能家电的控制。他们收集了健康受试者和中风后受试者的EEG信号, 并用FNB设计了上述EEGNet来对这些数据进行分类。这些应用的表现显示了基于深度学习的EEG信号处理方法的有效性和前景, 以及现实生活中BCI设备的可能性。

### 3.3.2. 多网络结构融合

目前存在着各种各样的神经网络和结构, 如CNN、RNN、注意机制、AutoEncoder (Encoder-Decoder)结构等, 在不同的应用场景下有着不同的性能。多种结构的融合可以通过组合不同的特征来提高分类精度([Singh et al., 2021](#))。据观察, 许多研究将辍学、BN和注意机制应用于深度学习算法。在被调查的28篇论文中, 使用dropout的有11篇(39.3%), BN的有11篇(39.3%), 注意机制的有7篇(25%)。

[Lin等人\(2022\)](#)提出了相位学习和频率注意网络(PLFA-Net), 该网络结合了相位学习模块、SAM、特征提取CNN和全连接层。相位学习模块通过计算FFT输出的实部和虚部的线性组合来学习相位信息。SAM提取的频率特征如上所述。特征提取CNN是一种传统的卷积层, 同时提取时间和通道的特征。PLFA-Net在高频性能优于CCA, 但在低频性能较差, 这可能是因为它能很好地提取高频的低幅值信息, 但受到低频噪声的影响。

[Lian等人\(2021\)](#)结合了浅层CNN (SCNN)、BiLSTM和注意机制来改进EEG分类。SCNN的设计灵感来自于Visual Geometry Group (VGG), 但SCNN使用形状为 $1 \times 5$ 和 $1 \times 3$ 的矩形核而不是方形核来提取时间特征。BiLSTM后采用注意机制融合SCNN和BiLSTM的特点。

[Li和Sun\(2022\)](#)使用改进的EEGNet和ConvLSTM对EEG信号进行处理。ConvLSTM结合RNN和CNN, 使用卷积运算传递隐藏状态。在ConvLSTM输入之前也采用了注意机制。该模型在多个数据集上取得了更好的效果。

### 3.3.3. 深度学习的问题和未来方向

虽然深度学习在处理EEG信号方面已被证明是有效的, 但仍存在一些值得注意的问题,

这些问题也是未来深度学习处理EEG信号的研究方向。在接下来的章节中, 我们将重点介绍其中的一些问题, 并为解决这些问题提供潜在的途径。

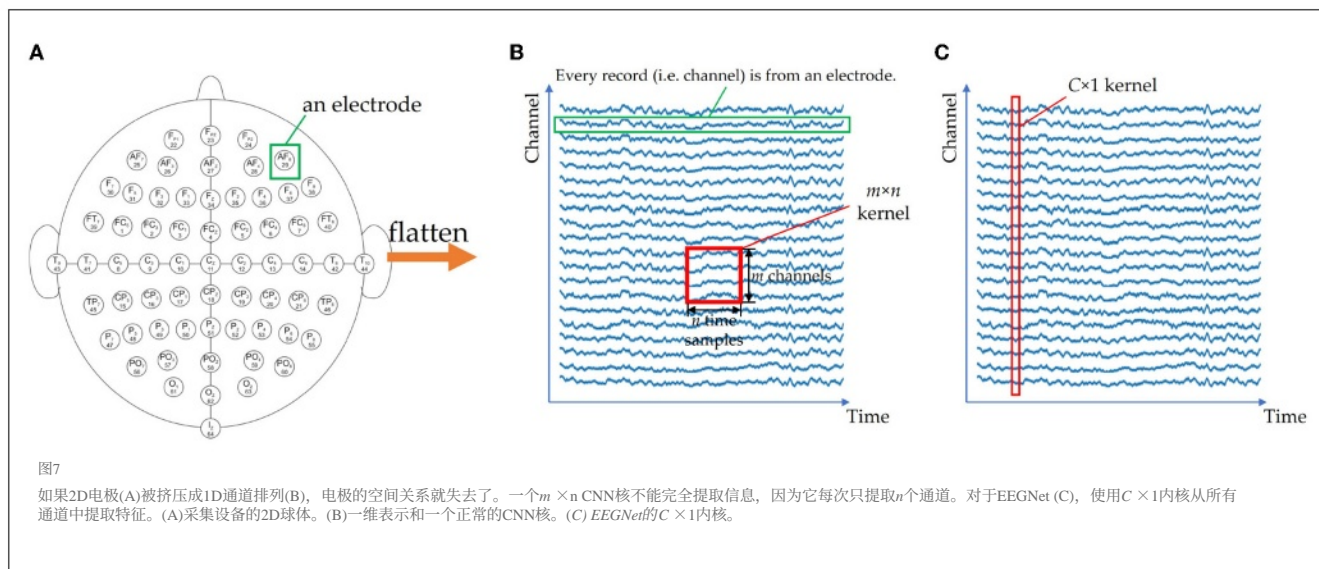
第一个问题与输入的形状有关。cnn通常接受二维图像或三维多通道图像作为输入, 而EEG信号是形状为 $C \times T$ 的多通道一维序列。直接使用 $2D \ C \times T$ 矩阵作为输入可能会导致卷积操作时特征提取不充分, 因为电极与3D球体上的四个周围电极相邻, 而在矩阵中只有两个相邻电极。[图7](#)说明了这一问题。一些研究者忽略了cnn的输入形状和属性, 使用了不合适的输入和传统的二维卷积层, 导致相关性提取效果不佳。例如, 在[Islam et al.\(2022\)](#)中, 应用小波变换作为特征提取步骤后, 将所有通道的频谱图串联成一个大的2D图像, 这可能会由于图像边界之间缺乏明显的关系而提取冗余特征。为了克服这些问题, 研究人员提出了创新的解决方案, 例如将每个通道视为一个独立的样本, 将信号转换为3D张量, 以保留电极的相对位置([Liu and Yang, 2021](#); [Bagchi和Bathula, 2022](#)), 或者在EEGNet (Lawhern等人, 2018)和EEG-TCFNet ([Vega等人, 2021](#))等模型中使用 $C \times 1$ 内核进行深度卷积层。在未来, 需要进一步关注设计能够适应EEG信号形状和特征的CNN结构, 从而有效地提取特征。

另一个问题涉及跨学科任务的准确性, 许多研究显示, 在被试内任务中准确率很高, 但在跨学科任务中准确率较低。例如, 在[Mattioli et al.\(2022\)](#)的研究中, 当将迁移学习应用于其他学科时, 准确率从学科内任务的99%急剧下降到约50%, 这表明参数对给定的个体过拟合, 不能轻易推广到新个体。这个问题是EEG应用和BCI技术的瓶颈, 其中所有参与者的通用分类器尚未设计。事实上, [Singh et al.\(2021\)](#)总结了一些提高独立于受试者的精度的方法, 但大多数是非深度学习或非深度学习和深度学习方法的融合。进一步研究基于深度学习的EEG信号处理, 以解决这一问题, 提高跨学科准确率。

准确度和时间成本之间的平衡是另一个在很多情况下需要考虑的挑战。更深入、更复杂的网络通常会带来更高的精度, 但也会带来更长的计算时间, 这在基于脑电图的实时应用(如用于控制设备的BCI)中可能会出现。一些研究, 如[Bagchi和Bathula\(2022\)](#)的研究, 虽然追求更高的精度, 但需要大量的参数和较高的时间成本来实现。另一方面, 一些研究使用了可分离卷积层等特殊结构, 可以在不显著增加计算时间的情况下保持较高的精度。在未来, 实现精度和计算时间之间的平衡仍将是一个重要的考虑因素。

最后, EEG和深度学习都缺乏可解释性, 这阻碍了进一步的发展。由于我们的大脑功能还没有完全被理解, 解释EEG信号





并且了解深度学习模型的工作原理可能具有挑战性。深度学习通常被认为是一个“黑匣子”(Adadi和Berrada, 2018), 这使得解释和理解EEG深度学习模型变得困难。此外, 由于我们不知道不同个体之间EEG信号的具体变化, 缺乏可解释性也是导致跨受试者准确性低的一个因素。许多论文试图从网络结构方面解释其网络高效的原因, 但现有的原因仍然非常主观。此外, Vallabhaneni等人(2021)指出, 在EEG和BCI的医学和心理学应用中, 病理机制比分类准确性更重要。但从我们回顾的论文来看, 研究人员仍然主要关注高性能, 或者更准确地说, 高准确性。因此, 在医学领域, EEG的深度学习仍然无法投入实际应用, 留下了一个重大的未解决问题。

### 3.4. 不同方法的融合

目前, 存在大量的分类算法。然而, 在不同的范式和应用场景下, 它们的性能差异很大。No Free Lunch定理断言, 不可能找到一种算法在任何数据分布上都能很好地泛化(Wolpert and Macready, 1997)。此外, 许多算法在处理过程中遇到挑战, 如特征提取不足、忽略全局网络特征、无法识别大脑的物理功能等。此外, 随着预处理方法和深度学习算法的发展和融合, 预处理、特征提取和分类之间的划分变得模糊。在Saeidi等人(2021)进行的综述中, ICA和PCA被分为预处理和特征提取两种方法。在大多数深度学习研究中, 特征被认为是由神经网络

自动提取的, 因此没有单一的特征提取步骤。与单一算法相比, 多算法融合可以优化特征选择, 降低计算复杂度, 并提高分类精度(Singh et al., 2021)。

我们的调查显示, 有45项研究(73.8%)采用了两种以上方法的融合来进行特征提取和分类, 导致了性能的显著提升。多算法融合正在成为EEG处理的新趋势。此外, 14篇论文利用BCI Competition IV 2a数据集进行研究, 如图8所示。Liu et al.(2021)利用LSTM和self-attention的融合, 在14篇论文中取得了最高的准确率(97.7%)。

#### 3.4.1. 多常规方法融合

尽管深度学习已经普及, 但许多传统的特征提取方法仍然适用于EEG, 特别是在特征提取方面。在实践中, 在选择各种常规算法时, 需要考虑可以获得的样本数量、训练时间、测试方法等各种因素的影响。通过组合, 可以获得最优的特征提取能力, 节省训练和分类的时间成本, 同时具有良好的泛化能力。我们的研究显示, 使用特征提取算法的16篇论文(26.2%)涉及到特征提取融合算法, 说明特征提取算法也有融合发展的趋势。准确率和准确率增量如图9所示。虽然在不同的研究中使用了不同的基准或分类算法, 但它们都实现了至少1%的精度增量。

例如, Sun等人(2021)提出了判别规范模式匹配(Discriminative Canonical Pattern Matching, DCPM)算法, 该算法集成了DSP、CCA和模式匹配, 在各种情况下都取得了最佳性能。与lda相关算法相比, DCPM在训练样本数量较少或特征数量过大时表现更好。与svm相关的相比




图8

不同方法在BCI competition IV dataset 2a上的精度比较。垂直轴上的每个标签代表一项研究中的一种方法，从上到下依次为：Gaur等人(2021)、Lashgari等人(2021)、Lian等人(2021)、Liu和Yang(2021)、Liu等人(2021)、Qi等人(2021)、Ali等人(2022)、Ayoobi和Sadeghian(2022)、Chang等人(2022)、Chen等人(2022)、Ko等人(2022)、Li和Sun(2022)、Li等人(2022)、Tang等人(2022)。

### Feature Extraction Algorithm Fusion Accuracy

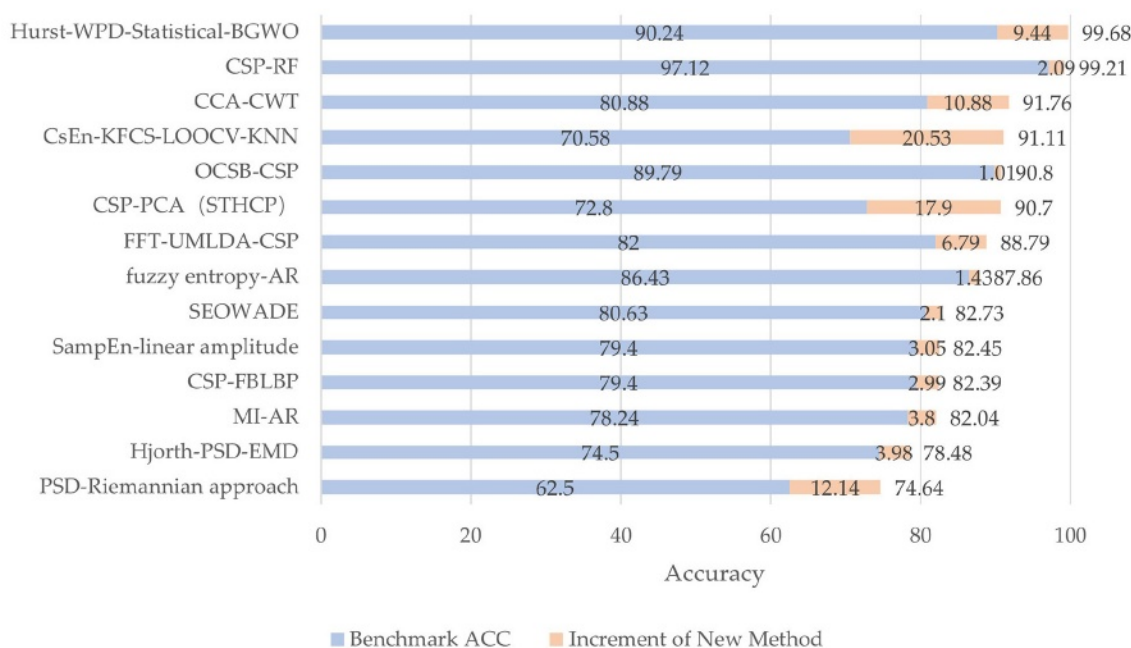


图9

不同融合方法的准确率和准确率增量。基准算法通常是以往研究中的方法或简单的CSP等常规算法，其准确率用蓝色条表示。创新方法是指论文中提出的新方法，其精度增量用橙色条表示。垂直轴上的每个标签代表一项研究中的一种方法，从上到下依次为：Du等人(2021)、高宁等人(2021)、Qi等人(2021)、Rashid等人(2021)、Wang和Quan(2021)、Xu C.等人(2021)、Yin等人(2021)、Zhang Y.等人(2021)、Algarni等人(2022)、Cui等人(2022)、Jia等人(2022)、Ma等人(2022)、Pei等人(2022)、Tang等人(2022)。

算法，DCPM避免了使用过程中长期的参数选择过程，使应用过程更容易。

Ma等人(2022)提出了CCA-CWT- svm融合算法，将CCA提取的特征与CWT相结合，实现特征互补

从而在有限的时间内显著提高了目标精度。

Yin等人(2021)提出了一种基于信道的最优稀疏时频块公共空间模式(OCSB-CSP)特征提取方法,以提高模型分类精度和计算效率。首先调用基于皮尔逊相关系数的通道选择方法,以减少通道之间的冗余信息,并标记出最佳通道以供后续处理。然后,通过定义费歇尔比指数对时频块进行稀疏化来衡量每个时频块的判别能力,显著降低了数据维度,所选择的时频块大多分布在与MI任务相关的频带中。最后进行Lasso回归的p形分析,选择提取的多块CSP特征并使用SVM进行分类。结果表明,本文提出的OCSB-CSP算法在降低模型计算量的同时达到了较高的分类精度。

### 3.4.2. 常规方法与深度学习的融合

除了修改3.3.1节讨论的深度学习算法外,一些研究还探索了常规方法与深度学习的融合。在这一节中,我们回顾了一些传统方法和深度学习的创新融合。

Islam等人(2022)提出了CNN与KNN的融合。CNN提取的特征在 $R^m$ 中作为一维向量处理,利用欧几里得距离进行KNN分类。

Algarni等人(2022)提出了Hurst指数、WPD、统计特征、二元灰狼优化(Binary Gray Wolf Optimization, BGWO)算法和BiLSTM的融合。利用Hurst指数测量时间序列的长期记忆变化,利用WPD更好地滤波离散时间信号,利用统计特征分析时域特征。采用Hurst、WPD和统计特征的融合提取特征。采用BGWO算法在保留重要信息的同时,对特征进行选择 and 剔除冗余特征。然后使用BiLSTM进一步提取特征,最后使用FC层进行分类。

### 3.4.3. 多方法融合的未来方向

多方法融合是EEG处理的发展方向。我们将尝试给出一些多方法融合重要的原因,并在本节中总结多方法融合的趋势。

首先,大脑的特性还没有被充分挖掘。EEG来源于我们大脑的神经活动,EEG信号处理的目的是解码和获取我们大脑的信息。然而,目前很少有研究者采用机器学习融合侧重于算法有效性的解释,以及将算法与认知机制相关联。虽然融合方法的有效性可以通过比较准确率等性能间接证明,但目前尚不清楚每个方法到底提

取了什么特征,以及特征的神经学含义是什么,因此对融合方法背后的认知机制还没有完全了解。因此,没有提出最优解或算法选择的一般解释(Chen等, 2022)。

其次,除了算法融合,其他融合方法如多样本融合也值得探索。Fan等(2021)利用SVM对EEG信号进行多样本融合分类,将相同实验条件下的多个样本进行组合,提高分类精度。这明显提高了SVM分类的准确性,而不是单个样本。

第三,单一特征可能无法有效捕捉大脑的生理行为。未来的研究可能会引入更多的参数来提高分类精度。但是,方法融合可能会导致时间和空间复杂度增加,导致训练和预测次数变长,这限制了模型的实际应用(Lu et al., 2022)。因此,平衡参数数量和时间成本是很重要的,以避免过拟合和过多的时间和空间复杂度。例如,在3.4.2节中,我们讨论了Algarni et al.(2022)使用多特征提取阶段和BiLSTM来降低数据维数,提高分类精度的研究。BiLSTM降低了数据的高维,降低了复杂性,减少了分类时间,提高了性能。

综上所述,多方法融合是EEG处理的一个很有前途的方向,需要更多的研究来充分挖掘其潜力。未来的研究可能侧重于理解融合方法背后的认知机制,探索其他融合方法,降低模型的局限性和复杂性。

## 4. 结论

本文对61项有关EEG处理的研究进行了综述。我们讨论了不同的预处理方法,并强调了适当的预处理方法对提高准确性的有效性,这解决了Alzahab等人(2021)综述中的问题。此外,我们观察到深度学习方法在EEG信号处理中的广泛采用,并讨论了它们变得普遍的一些原因。我们还注意到,许多研究应用了多方法融合,既使用了传统算法,也使用了深度学习。本文的总结为今后EEG信号处理的研究指明了方向。

尽管取得了这些进步,但由于我们对大脑的了解有限,我们在基于脑电图的脑机接口系统和EEG信号处理方面仍然面临着重大挑战。跨受试者精度低的问题也仍然没有得到解决,这表明泛化能力有限。设计一个更鲁棒、泛化能力更强、时间成本更少的系统仍然是未来研究的开放问题。

## 作者的贡献

CS和CM构思并设计了这项研究。CS收集了相关文献，并撰写了手稿的初稿。CM提供写作监督和批判性修改，最终定稿。两位作者都对文章做出了贡献，并批准了提交的版本。

## 资金

山东省自然科学基金(批准号:1090413702304)资助。

## 致谢

作者对审稿人的宝贵反馈表示感谢，这些反馈极大地促进了本文审稿质量的提高。

## 参考文献

- Adadi, A., and Berrada, M. (2018). Peeking inside the black-box: a survey on explainable artificial intelligence (xai). *IEEE Access* 6, 52138–52160. doi: 10.1109/ACCESS.2018.2870052
- Aellen, F. M., Goktepe-Kavis, P., Apostolopoulos, S., and Tzovara, A. (2021). Convolutional neural networks for decoding electroencephalography responses and visualizing trial by trial changes in discriminant features. *J. Neurosci. Methods* 364, 109367. doi: 10.1016/j.jneumeth.2021.109367
- Al-Fahoum, A. S., and Al-Fraihat, A. A. (2014). Methods of eeg signal features extraction using linear analysis in frequency and time-frequency domains. *ISRN Neurosci.* 2014, 730218. doi: 10.1155/2014/730218
- Algarni, M., Saeed, F., Al-Hadhrami, T., Ghabban, F., and Al-Sarem, M. (2022). Deep learning-based approach for emotion recognition using electroencephalography (EEG) signals using bi-directional long short-term memory (Bi-LSTM). *Sensors* 22, s22082976. doi: 10.3390/s22082976
- Ali, O., Saif-Ur-Rehman, M., Dyck, S., Glasmachers, T., Iossifidis, I., and Klaes, C. (2022). Enhancing the decoding accuracy of eeg signals by the introduction of anchored-STFT and adversarial data augmentation method. *Sci. Rep.* 12, 4245. doi: 10.1038/s41598-022-07992-w
- Alzahab, N. A., Apollonio, L., Di Iorio, A., Alshalak, M., Iarlori, S., Ferracuti, F., et al. (2021). Hybrid deep learning (HDL)-based brain-computer interface (BCI) systems: a systematic review. *Brain Sci.* 11, brainsci11010075. doi: 10.3390/brainsci11010075
- Asadzadeh, S., Yousefi Rezaii, T., Beheshti, S., and Meshgini, S. (2022). Accurate emotion recognition using bayesian model based EEG sources as dynamic graph convolutional neural network nodes. *Sci. Rep.* 12, 10282. doi: 10.1038/s41598-022-14217-7
- Asensio-Cubero, J., Gan, J. Q., and Palaniappan, R. (2013). Multiresolution analysis over simple graphs for brain computer interfaces. *J. Neural Eng.* 10, e046014. doi: 10.1088/1741-2560/10/4/046014
- Asheri, B., Haratian, A., Mohamadi, M., Asadi, F., Yasini, P., Zarepak, N., et al. (2021). Enhancing detection of steady-state visual evoked potentials using frequency and harmonics of that frequency in openvibe. *Biomed. Eng. Adv.* 2, 100022. doi: 10.1016/j.bea.2021.100022
- Ashwini S. R., and Nagaraj, H. C. (2021). Classification of EEG signal using EACA based approach at SSVEP-BCI. *IAES Int. J. Artif. Intell.* 10, 726. doi: 10.11591/ijai.v10.i3.pp717-726
- Awais, M. A., Yusoff, M. Z., Khan, D. M., Yahya, N., Kamel, N., and Ebrahim, M. (2021). Effective connectivity for decoding electroencephalographic motor imagery using a probabilistic neural network. *Sensors* 21, s21196570. doi: 10.3390/s21196570
- Ayoobi, N., and Sadeghian, E. B. (2022). “Unsupervised motor imagery saliency detection based on self-attention mechanism,” in *2022 44th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC) (IEEE)*, 4817–4820. doi: 10.1109/EMBC48229.2022.9871906
- Azizpour, H., Razavian, A. S., Sullivan, J., Maki, A., and Carlsson, S. (2016). Factors of transferability for a generic convnet representation. *IEEE Trans. Pat. Anal. Mach. Intell.* 38, 1790–802. doi: 10.1109/TPAMI.2015.2500224
- Bagchi, S., and Bathula, R. D. (2022). EEG-convtransformer for single-trial EEG based visual stimulus classification. *Pat. Recogn.* 129, 108757. doi: 10.1016/j.patcog.2022.108757
- Bashashati, A., Fatourehchi, M., Ward, R. K., and Birch, G. E. (2007). A survey of signal processing algorithms in brain-computer interfaces based on electrical brain signals. *J. Neural Eng.* 4, R32–R57. doi: 10.1088/1741-2560/4/2/R03
- Cai, Z., Guo, M., Yang, X., Chen, X., and Xu, G. (2021). Cross-subject electroencephalogram emotion recognition based on maximum classifier discrepancy. *J. Biomed. Eng.* 38, 455–462. doi: 10.7507/1001-5515.202012027
- Cano-Izquierdo, J. M., Ibarrola, J., and Almonacid, M. (2012). Improving motor imagery classification with a new BCI design using neuro-fuzzy S-dFasArt. *IEEE Trans. Neural Syst. Rehabil. Eng.* 20, 2–7. doi: 10.1109/TNSRE.2011.2169991
- Chang, Z., Zhang, C., and Li, C. (2022). Motor imagery EEG classification based on transfer learning and multi-scale convolution network. *Micromachines* 13, 60927. doi: 10.3390/mi13060927
- Chen, J., Min, C., Wang, C., Tang, Z., Liu, Y., and Hu, X. (2022). Electroencephalograph-based emotion recognition using brain connectivity feature and domain adaptive residual convolution model. *Front. Neurosci.* 16, 878146. doi: 10.3389/fnins.2022.878146
- Chen, L., Gong, A., and Ding, P. (2022). EEG signal decoding of motor imagination based on euclidean space-weighted logistic regression transfer learning. *J. Nanjing Univ.* 58, 264–274. doi: 10.13232/j.cnki.jnju.2022.02.010
- Chen, Z., and Xie, K. (2019). *A Review of EEG-Based Analysis and Classification Methods*.
- Cona, F., Zavaglia, M., Astolfi, L., Babiloni, F., and Ursino, M. (2009). Changes in EEG power spectral density and cortical connectivity in healthy and tetraplegic patients during a motor imagery task. *Comput. Intell. Neurosci.* 2009, 279515. doi: 10.1155/2009/279515
- Cui, Y., Xie, S., Xie, X., Duan, X., and Gao, C. (2022). A spatial-temporal hybrid feature extraction method for rapid serial visual presentation of electroencephalogram signals. *Chin. J. Biomed. Eng.* 39, 39–46. doi: 10.7507/1001-5515.202104049
- Dagdevir, E., and Tokmakci, M. (2021). Optimization of preprocessing stage in EEG based BCI systems in terms of accuracy and timing cost. *Biomed. Sign. Process. Contr.* 67, 102548. doi: 10.1016/j.bspc.2021.102548

## 利益冲突

作者声明，该研究是在没有任何商业或财务关系的情况下进行的，这些关系可被视为潜在的利益冲突。

## 出版商的注意

本文中所表达的所有主张仅代表作者的主张，并不代表其附属组织的主张，也不代表出版者、编辑和审稿人的主张。任何可能在本文中被评估的产品，或可能由其制造商做出的声明，都不得得到出版者的保证或认可。

## 补充材料

本文的补充材料可以在网上找到:<https://www.frontiersin.org/articles/10.3389/fnins.2023.1203059/#补充材料>



- De Venuto, D., and Mezzina, G. (2021). A single-trial p300 detector based on symbolized EEG and autoencoded-(1D)CNN to improve ITR performance in BCIs. *Sensors* 21, s21123961. doi: 10.3390/s21123961
- Delorme, A., and Makeig, S. (2004). EEGLAB: an open source toolbox for analysis of single-trial EEG dynamics including independent component analysis. *J. Neurosci. Methods* 134, 9–21. doi: 10.1016/j.jneumeth.2003.10.009
- Du, Y., Liu, Z., and Fu, Z. (2021). Motion imagery classification algorithm research based on hybrid transfer learning and application in brain-computer interface. *Acta Metrol. Sin.* 45, 629–637. doi: 10.3969/j.issn.1000-1158.2021.05.14
- Duan, Y., Zhou, J., Wang, Z., Chang, Y.-C., Wang, Y.-K., and Lin, C.-T. (2023). Domain-specific denoising diffusion probabilistic models for brain dynamics. *arXiv [Preprint]*. arXiv: 2305.04200. Available online at: <https://arxiv.org/pdf/2305.04200.pdf>
- El-Kafrawy, N. M., Hegazy, D., and Tolba, M. F. (2014). “Features extraction and classification of EEG signals using empirical mode decomposition and support vector machine,” in *Advanced Machine Learning Technologies and Applications*, eds A. E. Hassanien, M. F. Tolba, and A. Taher Azar (Cham: Springer International Publishing), 189–198.
- Fan, C., Hu, J., Huang, S., Peng, Y., and Kwong, S. (2022). EEG-TNET: an end-to-end brain computer interface framework for mental workload estimation. *Front. Neurosci.* 16, 869522. doi: 10.3389/fnins.2022.869522
- Fan, W., Luo, S., Deng, Y., and Li, Y. (2021). Support vector machine algorithm with multi-sample fusion for p300 signal classification. *J. Wuhan Inst. Technol.* 43, 670–674. doi: 10.19843/j.cnki.CN42-1779/TQ.202101006
- Ferracuti, F., Iarlori, S., Mansour, Z., Monteriu, A., and Porcaro, C. (2021). Comparing between different sets of preprocessing, classifiers, and channels selection techniques to optimise motor imagery pattern classification system from EEG pattern recognition. *Brain Sci.* 12, 10057. doi: 10.3390/brainsci12010057
- Gao, N., Gao, Z., and Zhang, H. (2021). Riemannian approach research for the feature extraction and classification of motor imagery electroencephalogram (EEG) signals. *J. Biomed. Eng. Res.* 40, 246–251. doi: 10.19529/j.cnki.1672-6278.2021.03.04
- Gao, Z., Dang, W., Liu, M., Guo, W., Ma, K., and Chen, G. R. (2021). Classification of EEG signals on VEP-based bci systems with broad learning. *IEEE Trans. Syst. Man Cybernet.* 51, 7143–7151. doi: 10.1109/tsmc.2020.2964684
- Gaur, P., Gupta, H., Chowdhury, A., McCreadie, K., Pachori, R., and Wang, H. (2021). A sliding window common spatial pattern for enhancing motor imagery classification in EEG-BCI. *IEEE Trans. Instrument. Measur.* 70, 1–9. doi: 10.1109/TIM.2021.3051996
- Geng, X., Li, D., Chen, H., Yu, P., Yan, H., and Yue, M. (2022). An improved feature extraction algorithms of EEG signals based on motor imagery brain-computer interface. *Alexandria Eng. J.* 61, 4807–4820. doi: 10.1016/j.aej.2021.10.034
- Hamed, M., Salleh Sh, H., and Noor, A. M. (2016). Electroencephalographic motor imagery brain connectivity analysis for BCI: a review. *Neural Comput.* 28, 999–1041. doi: 10.1162/NECO\_a\_00838
- He, C., Liu, J., Zhu, Y., and Du, W. (2021). Data augmentation for deep neural networks model in EEG classification task: a review. *Front. Hum. Neurosci.* 15, 765525. doi: 10.3389/fnhum.2021.765525
- He, K., Zhang, X., and Ren, S. (2016). “Deep residual learning for image recognition,” in *Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition* (Las Vegas, NV), 770–778.
- Islam, M. N., Sulaiman, N., Bari, B. S., Rashid, M., and Mustafa, M. (2022). A hybrid scheme for AEP based hearing deficiency diagnosis: CWT and convoluted K-nearest neighbour (CKNN) pipeline. *Neurosci. Informat.* 2, 100037. doi: 10.1016/j.neuri.2021.100037
- Jeong, J. H., Shim, K. H., Kim, D. J., and Lee, S. W. (2020). Brain-controlled robotic arm system based on multi-directional CNN-BiLSTM network using EEG signals. *IEEE Trans. Neural Syst. Rehabil. Eng.* 28, 1226–1238. doi: 10.1109/TNSRE.2020.2981659
- Jia, T., Dong, C., and Ma, S. (2022). Brain-computer interface of motor imaging based on multi information feature extraction. *Chin. J. Med. Phys.* 39, 63–68. doi: 10.3969/j.issn.1005-202X.2022.01.011
- Kim, C., Sun, J., Liu, D., Wang, Q., and Paek, S. (2018). An effective feature extraction method by power spectral density of EEG signal for 2-class motor imagery-based BCI. *Med. Biol. Eng. Comput.* 56, 1645–1658. doi: 10.1007/s11517-017-1761-4
- Kim, S., Shin, D. Y., Kim, T., Lee, S., Hyun, J. K., and Park, S. M. (2022). Enhanced recognition of amputated wrist and hand movements by deep learning method using multimodal fusion of electromyography and electroencephalography. *Sensors* 22, s22020680. doi: 10.3390/s22020680
- Ko, W., Jeon, E., Yoon, J. S., and Suk, H. I. (2022). Semi-supervised generative and discriminative adversarial learning for motor imagery-based brain-computer interface. *Sci. Rep.* 12, 4587. doi: 10.1038/s41598-022-08490-9
- Kumar, J. S., and Bhuvaneswari, P. (2012). Analysis of electroencephalography (EEG) signals and its categorization—a study. *Proc. Eng.* 38, 2525–2536. doi: 10.1016/j.proeng.2012.06.298
- Kumar, S., Tsunoda, T., and Sharma, A. (2021). Spectra: a tool for enhanced brain wave signal recognition. *BMC Bioinform.* 22(Suppl.6), 195. doi: 10.1186/s12859-021-04091-x
- Lashgari, E., Liang, D., and Maoz, U. (2020). Data augmentation for deep-learning-based electroencephalography. *J. Neurosci. Methods* 346, 108885. doi: 10.1016/j.jneumeth.2020.108885
- Lashgari, E., Ott, J., Connelly, A., Baldi, P., and Maoz, U. (2021). An end-to-end CNN with attentional mechanism applied to raw EEG in a BCI classification task. *J. Neural Eng.* 18, e0460e3. doi: 10.1088/1741-2552/ac1ade
- Lawhern, V. J., Solon, A. J., Waytowich, N. R., Gordon, S. M., Hung, C. P., and Lance, B. J. (2018). EEGNet: a compact convolutional neural network for EEG-based brain-computer interfaces. *J. Neural Eng.* 15, e056013. doi: 10.1088/1741-2552/aace8c
- Li, H., Ding, M., and Zhang, R. (2022). Motor imaginative EEG classification algorithm based on feature fusion neural network. *Chin. J. Med. Phys.* 39, 69–75. doi: 10.3969/j.issn.1005-202X.2022.01.012
- Li, L., and Sun, N. (2022). Attention-based DSC-ConvLSTM for multiclass motor imagery classification. *Comput. Intell. Neurosci.* 2022, 8187009. doi: 10.1155/2022/8187009
- Li, Q., Shi, K., Gao, N., Li, J., and Bai, O. (2018). Training set extension for SVM ensemble in p300-speller with familiar face paradigm. *Technol. Health Care* 26, 469–482. doi: 10.3233/THC-171074
- Li, Q., Wu, Y., Song, Y., Zhao, D., Sun, M., Zhang, Z., et al. (2022). A p300-detection method based on logistic regression and a convolutional neural network. *Front. Comput. Neurosci.* 16, 909553. doi: 10.3389/fncom.2022.909553
- Lian, S., Xu, J., Zuo, G., Wei, X., and Zhou, H. (2021). A novel time-incremental end-to-end shared neural network with attention-based feature fusion for multiclass motor imagery recognition. *Comput. Intell. Neurosci.* 2021, 6613105. doi: 10.1155/2021/6613105
- Lin, Y., Zang, B., and Guo, R. (2022). A deep learning method for SSVEP classification based on phase and frequency characteristics. *J. Electr. Inform. Technol.* 44, 446–454. doi: 10.11999/JEIT210816
- Liu, C., and Jin, J. (2021). Ji yu shuang pu de wen tai shi jue you fa dian wei nao ji jie kou dao lian xuan ze suan fa. *Ren Gong Zhi Neng*, 6:52–60. doi: 10.16453/j.cnki.ISSN2096-5036
- Liu, J., Ye, F., and Xiong, H. (2021). Multi-class motor imagery EEG classification method with high accuracy and low individual differences based on hybrid neural network. *J. Neural Eng.* 18, ac1ed0. doi: 10.1088/1741-2552/ac1ed0
- Liu, T., and Yang, D. (2021). A three-branch 3D convolutional neural network for EEG-based different hand movement stages classification. *Sci. Rep.* 11, 10758. doi: 10.1038/s41598-021-89414-x
- Liu, T., and Yao, D. (2006). Removal of the ocular artifacts from EEG data using a cascaded spatio-temporal processing. *Comput. Methods Progr. Biomed.* 83, 95–103. doi: 10.1016/j.cmpb.2006.03.009
- Liu, Y., Zhang, H., Chen, M., and Zhang, L. (2016). A boosting-based spatial-spectral model for stroke patients’ EEG analysis in rehabilitation training. *IEEE Trans. Neural Syst. Rehabil. Eng.* 24, 169–179. doi: 10.1109/TNSRE.2015.2466079
- Lu, R., Zeng, Y., Zhang, R., Yan, B., and Tong, L. (2022). SAST-GCN: segmentation adaptive spatial temporal-graph convolutional network for p3-based video target detection. *Front. Neurosci.* 16, 913027. doi: 10.3389/fnins.2022.913027
- Luo, T. J., Zhou, C. L., and Chao, F. (2018). Exploring spatial-frequency-sequential relationships for motor imagery classification with recurrent neural network. *BMC Bioinform.* 19, 344. doi: 10.1186/s12859-018-2365-1
- Ma, P., Dong, C., Lin, R., Ma, S., Jia, T., Chen, X., et al. (2022). A classification algorithm of an SSVEP brain-computer interface based on cca fusion wavelet coefficients. *J. Neurosci. Methods* 371, 109502. doi: 10.1016/j.jneumeth.2022.109502
- Mane, R., Robinson, N., Vinod, A. P., Lee, S. W., and Guan, C. (2020). A multi-view CNN with novel variance layer for motor imagery brain computer interface. *Annu. Int. Conf. IEEE Eng. Med. Biol. Soc.* 2020, 2950–2953. doi: 10.1109/EMBC44109.2020.9175874
- Maruyama, Y., Ogata, Y., Martinez-Tejada, L. A., Koike, Y., and Yoshimura, N. (2020). Independent components of EEG activity correlating with emotional state. *Brain Sci.* 10, brainsci10100669. doi: 10.3390/brainsci10100669
- Mattioli, F., Porcaro, C., and Baldassarre, G. (2022). A 1D CNN for high accuracy classification and transfer learning in motor imagery EEG-based brain-computer interface. *J. Neural Eng.* 18, doi: 10.1088/1741-2552/ac4430
- Meng, M., Dong, Z., and Gao, Y. (2022). Correlation and sparse representation based channel selection of motor imagery electroencephalogram. *J. Electr. Inform. Technol.* 44, 477–485. doi: 10.11999/JEIT210778
- Michel, C. M., and Murray, M. M. (2012). Towards the utilization of EEG as a brain imaging tool. *NeuroImage* 61, 371–385. doi: 10.1016/j.neuroimage.2011.12.039
- Nakagome, S., Luu, T. P., He, Y., Ravindran, A. S., and Contreras-Vidal, J. L. (2020). An empirical comparison of neural networks and machine learning algorithms for EEG gait decoding. *Sci. Rep.* 10, 4372. doi: 10.1038/s41598-020-60932-4

- Okafor, E., Smit, R., Schomaker, L., and Wiering, M. (2017). "Operational data augmentation in classifying single aerial images of animals," in *2017 IEEE International Conference on Innovations in Intelligent Systems and Applications (INISTA)* (Gdynia), p. 354–360. doi: 10.1109/INISTA.2017.8001185
- Park, S. H., Lee, D., and Lee, S. G. (2018). Filter bank regularized common spatial pattern ensemble for small sample motor imagery classification. *IEEE Trans. Neural Syst. Rehabil. Eng.* 26, 498–505. doi: 10.1109/TNSRE.2017.2757519
- Pei, Y., Luo, Z., Zhao, H., Xu, D., Li, W., Yan, Y., et al. (2022). A tensor-based frequency features combination method for brain-computer interfaces. *IEEE Trans. Neural Syst. Rehabil. Eng.* 30, 465–475. doi: 10.1109/TNSRE.2021.3125386
- Qi, F., Wang, W., Xie, X., Gu, Z., Yu, Z. L., Wang, F., et al. (2021). Single-trial EEG classification via orthogonal wavelet decomposition-based feature extraction. *Front. Neurosci.* 15, 715855. doi: 10.3389/fnins.2021.715855
- Rashid, M., Bari, B. S., Hasan, M. J., Razman, M. A. M., Musa, R. M., Ab Nasir, A. F., et al. (2021). The classification of motor imagery response: an accuracy enhancement through the ensemble of random subspace K-NN. *PeerJ Comput. Sci.* 7, e374. doi: 10.7717/peerj-cs.374
- Saeidi, M., Karwowski, W., Farahani, F. V., Fiok, K., Taiar, R., Hancock, P. A., et al. (2021). Neural decoding of EEG signals with machine learning: a systematic review. *Brain Sci.* 11, brainsci1111525. doi: 10.3390/brainsci1111525
- Sanei, S., and Chambers, J. A. (2021). *EEG Signal Processing and Machine Learning*. Hoboken, NJ: John Wiley & Sons.
- Singh, A., Hussain, A. A., Lal, S., and Guesgen, H. W. (2021). A comprehensive review on critical issues and possible solutions of motor imagery based electroencephalography brain-computer interface. *Sensors* 21, s21062173. doi: 10.3390/s21062173
- Song, C., Sheng, Y., and Ning, Z. (2022). Deep learning-based method for recognition of motion imagery EEG signal. *Transducer Microsyst. Technol.* 41, 125–133. doi: 10.13873/J.1000-9787(2022)04-0125-04
- Suhaimi, N. S., Mountstephens, J., and Teo, J. (2022). A dataset for emotion recognition using virtual reality and EEG (DER-VREEG): Emotional state classification using low-cost wearable VR-EEG headsets. *Big Data Cogn. Comput.* 6, bdcc6010016. doi: 10.3390/bdcc6010016
- Sun, J., Jung, T. P., Xiao, X., Meng, J., Xu, M., and Ming, D. (2021). Classification algorithms of error-related potentials in brain-computer interface. *Sheng Wu Yi Xue Gong Cheng Xue Za Zhi* 38, 463–472. doi: 10.7507/1001-5515.202012013
- Tang, X., Wang, T., Du, Y., and Dai, Y. (2019). Motor imagery EEG recognition with KNN-based smooth auto-encoder. *Artif. Intell. Med.* 101, 101747. doi: 10.1016/j.artmed.2019.101747
- Tang, Y., Zhao, Z., Zhang, S., Li, Z., Mo, Y., Guo, Y., et al. (2022). Motor imagery EEG decoding based on new spatial-frequency feature and hybrid feature selection method. *Math. Probl. Eng.* 2022, 1–12. doi: 10.1155/2022/2856818
- Torres, P. E., Torres, E. A., Hernandez-Alvarez, M., and Yoo, S. G. (2020). EEG-based BCI emotion recognition: a survey. *Sensors* 20, s20185083. doi: 10.3390/s20185083
- Vallabhaneni, R. B., Sharma, P., Kumar, V., Kulshreshtha, V., Reddy, K. J., Kumar, S. S., et al. (2021). Deep learning algorithms in EEG signal decoding application: a review. *IEEE Access* 9, 125778–125786. doi: 10.1109/ACCESS.2021.3105917
- Varsehi, H., and Firoozabadi, S. M. P. (2021). An EEG channel selection method for motor imagery based brain-computer interface and neurofeedback using granger causality. *Neural Netw.* 133, 193–206. doi: 10.1016/j.neunet.2020.11.002
- Vega, C. F., Quevedo, J., Escandon, E., Kianic, M., Dingd, W., and Andreu-Perez, J. (2021). Fuzzy temporal convolutional neural networks in p300-based brain-computer interface for smart home interaction. *Appl. Soft Comput.* 117, 108359. doi: 10.1016/j.asoc.2021.108359
- Vidaurre, C., Kawanabe, M., von Bunau, P., Blankertz, B., and Muller, K. R. (2011). Toward unsupervised adaptation of LDA for brain-computer interfaces. *IEEE Trans. Biomed. Eng.* 58, 587–97. doi: 10.1109/TBME.2010.2093133
- Vorontsova, D., Menshikov, I., Zubov, A., Orlov, K., Rikunov, P., Zvereva, E., et al. (2021). Silent EEG-speech recognition using convolutional and recurrent neural network with 85% accuracy of 9 words classification. *Sensors* 21, s21206744. doi: 10.3390/s21206744
- Wahid, M. F., and Tafreshi, R. (2021). Improved motor imagery classification using regularized common spatial pattern with majority voting strategy. *IFAC-PapersOnLine* 54, 226–231. doi: 10.1016/j.ifacol.2021.11.179
- Wang, P., Jiang, A., Liu, X., Shang, J., and Zhang, L. (2018). LSTM-based EEG classification in motor imagery tasks. *IEEE Trans. Neural Syst. Rehabil. Eng.* 26, 2086–2095. doi: 10.1109/TNSRE.2018.2876129
- Wang, Q., and Quan, H. (2021). Research on the classification of motor imagery EEG by optimized svm based surface-simplex swarm evolution. *J. Electr. Measur. Instrument.* 35, 157–163. doi: 10.13382/j.jemi.B2103989
- Wolpaw, J. R., Birbaumer, N., Heetderks, W. J., McFarland, D. J., Peckham, P. H., Schalk, G., et al. (2000). Brain-computer interface technology: a review of the first international meeting. *IEEE Trans. Rehabil. Eng.* 8, 164–173. doi: 10.1109/tre.2000.847807
- Wolpaw, J. R., McFarland, D. J., Vaughan, T. M., and Schalk, G. (2003). The wadsworth center brain-computer interface (BCI) research and development program. *IEEE Trans. Neural Syst. Rehabil. Eng.* 11, 204–7. doi: 10.1109/TNSRE.2003.814442
- Wolpert, D. H., and Macready, W. G. (1997). No free lunch theorems for optimization. *IEEE Trans. Evolution. Comput.* 1, 67–82.
- Xu, C., Zhang, H., and Sun, L. (2021). Prediction of hand grip motion intention based on sample entropy and time-frequency analysis. *J. Zhejiang Univ.* 55, 2315–2322. doi: 10.3785/j.issn.1008-973X.2021.12.011
- Xu, F., Miao, Y., Sun, Y., Guo, D., Xu, J., Wang, Y., et al. (2021). A transfer learning framework based on motor imagery rehabilitation for stroke. *Sci. Rep.* 11, 19783. doi: 10.1038/s41598-021-99114-1
- Xu, M., Wang, D., Li, Z., and Chen, Y. (2022). Incepa-ecgnet: p300 signal detection method based on fusion of inception network and attention mechanism. *J. Zhejiang Univ.* 56, 745–753. doi: 10.3785/j.issn.1008-973X.2022.04.014
- Yin, X., Meng, M., She, Q., Gao, Y., and Luo, Z. (2021). Optimal channel-based sparse time-frequency blocks common spatial pattern feature extraction method for motor imagery classification. *Math. Biosci. Eng.* 18, 4247–4263. doi: 10.3934/mbe.2021213
- Ying, J., Wei, Q., and Zhou, X. (2022). Riemannian geometry-based transfer learning for reducing training time in C-VEP BCIs. *Sci. Rep.* 12, 9818. doi: 10.1038/s41598-022-14026-y
- Zhang, A., Lipton, Z. C., Li, M., and Smola, A. J. (2021). Dive into deep learning. *arXiv [Preprint]. arXiv: 2106.11342*. Available online at: <https://arxiv.org/pdf/2106.11342.pdf>
- Zhang, K., Xu, G., Du, C., Wu, Y., Zheng, X., Zhang, S., et al. (2021). Weak feature extraction and strong noise suppression for SSVEP-EEG based on chaotic detection technology. *IEEE Trans. Neural Syst. Rehabil. Eng.* 29, 862–871. doi: 10.1109/TNSRE.2021.3073918
- Zhang, K., Xu, G., Zheng, X., Li, H., Zhang, S., Yu, Y., et al. (2020). Application of transfer learning in EEG decoding based on brain-computer interfaces: a review. *Sensors* 20, 6321. doi: 10.3390/s20216321
- Zhang, Y., Liao, Y., Zhang, Y., and Huang, L. (2021). Emergency braking intention detect system based on K-order propagation number algorithm: a network perspective. *Brain Sci.* 11, brainsci1111424. doi: 10.3390/brainsci11111424
- Zhao, X., Jin, J., Xu, R., Li, S., Sun, H., Wang, X., et al. (2022). A regional smoothing block sparse bayesian learning method with temporal correlation for channel selection in p300 speller. *Front. Hum. Neurosci.* 16, 875851. doi: 10.3389/fnhum.2022.875851