



第 4 章 感知 (3)

- ◆ 图像预处理和边缘检测
- ◆ 霍夫变换：直线提取方法
- ◆ 特征检测中的误差传播（协方差矩阵计算）
- ◆ 特征



特征提取

计算机视觉的方案和工具

- ◇ 一般地，特征识别是一个复杂过程，需要多种步骤逐步将图标数据转换为识别信息。
 - ◇ 图像预处理、图像处理、图像后处理
- ◇ 处理不限定环境，依然是非常具有挑战性的课题。
 - ◇ 噪声变化、光照变化、遮挡、旋转、尺度变化、变形、雨、雾、抖动

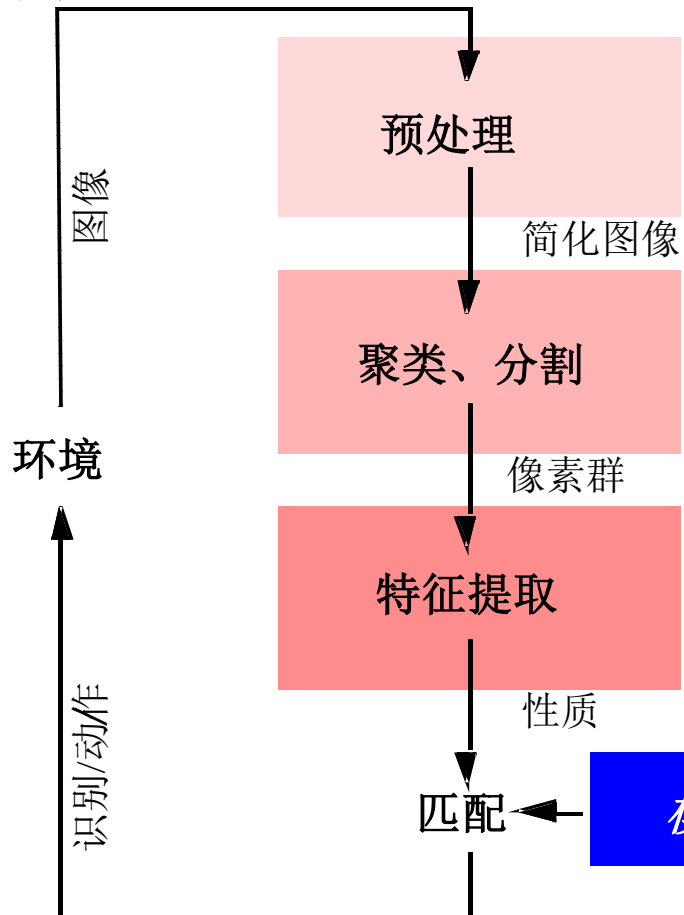


基于可视表象的特征提取 (视觉)

计算机视觉工具

图像处理方案

计算机视觉



阈值化
二值图像

边缘
检测

滤波

连接
元件
标记

直线提取

相关

霍夫变换


语义分割
实例分割

识别

显示




特征提取 – 场景解释



- ◆ 一个移动机器人必须能够根据感知和解释所测量的信号，确定它与环境的关系。
 - ◆ 如在前面章节所示，有种类繁多的感知技术可以利用。
 - ◆ 然而，主要困难在于解释这些数据，即，确定传感器得到的信号告诉我们关于环境什么。
- ◆ 选择传感器 (如，室内；室外；墙；开放空间 ...)
- ◆ 选择环境模型




特征提取 – 场景解释



- ◇ 存在两种用不确定的传感器信息引导机器人的策略：
 - ◇ 将传感器测量值与机器人行为直接联系起来，使机器人的动作成为传感器信息的函数。
 - ◇ 用传感器测量值更新当前模型，而机器人的动作是模型的函数。
- ◇ 第二种策略首先从一个或多个传感器数据中提取信息，产生较高级的感觉，然后用其更改机器人的模型（间接地对机器人的行为产生影响）或直接通知机器人的动作生成模块。
- ◇ 所谓“产生较高级的感觉”：这里对应“特征提取”。



特征提取 – 场景解释



- ◆ 实际上，机器人并不需要对每一个动作都经历上面完整的感知流程。
- ◆ 例如，对于避障问题，
 - ◆ 检测到正面近处障碍时立即停止移动；
 - ◆ 检测到稍远的前方障碍时，采用与地图结合的局部避障功能；
 - ◆ 对于远处的障碍，则可以修正地图后采用重新规划路径的方式以取得尽可能优化的移动效果。



特征

- ◆ 特征是环境中可辨别的元素或几何基元。
- ◆ 它们通常可以从测量和数学描述中提取出来。
 - ◆ 低级特征 (几何基元), 如直线, 圆
 - ◆ 高级特征, 如边缘, 门, 桌子或垃圾桶

在移动机器人中, 特征有助于定位和构建地图。



环境表示和建模 → 特征

◇ 环境表示


- ◇ 连续度量 → x, y, θ
- ◇ 离散度量 → 度量栅格
- ◇ 离散拓扑 → 拓扑栅格

◇ 环境建模


- ◇ 原始传感器数据，如，激光测程数据，灰度图像
 - ◇ 数据量大，独特性小
 - ◇ 利用所有获得的信息
- ◇ 低级特征，如，直线或其它几何特征
 - ◇ 数据量中等，独特性一般
 - ◇ 过滤得到有用信息，但仍然含糊
- ◇ 高级特征，如，门，一辆车，埃菲尔铁塔
 - ◇ 数据量小，独特性高
 - ◇ 过滤得到有用信息，很少或没有含糊性，信息不充分



环境模型：例



A: 基于特征的模型



B: 占有格



基于测距图像的特征提取

- ◆ 几何基元，如直线段、圆、角、边缘
- ◆ 对于大多数其它几何基元，特征的参数描述太复杂，没有闭式解。
- ◆ 然而，对于环境建模，尤其对室内环境，线段通常已足够了。



特征提取 (视觉): 工具

- ◇ 图像预处理
 - ◇ 抑制噪声
 - ◇ 对背景标准化, 通过抑制不感兴趣的系统性或模式化的背景变化
 - ◇ 做法:
 - ◇ 灰度比例调整 (如, 加阈值)
 - ◇ (低通) 滤波
- ◇ 标记
 - ◇ 测定事件的空间排列, 如, 搜索一个结构
- ◇ 分组
 - ◇ 辨认事件, 将带有同种事件的像素收集到一起。
- ◇ 提取
 - ◇ 对各组, 计算一系列特性
- ◇ 匹配 (见第五章)



滤波和边缘检测

◇ 高斯平滑

◇ 去除高频噪声 $\hat{I} = G \otimes I$

◇ 光强图像 I 与 G 求卷积:

其中,
$$G = \frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$$

◇ 边缘

◇ 亮度急剧变化的位置

◇ 对图像一次或二次求导



◇ 寻找出现导数绝对值大的位置

◇ 因为噪声, 在边缘检测之间需要先滤波/平滑处理



边缘检测

- ◇ 边缘检测的最终目的
 - ◇ 画出理想化的线
- ◇ 图像中的边缘轮廓，相当于重要的景象轮廓







边缘检测: Canny

- ◇ 处理步骤
 - ◇ 求图像与高斯函数 G 的卷积
 - ◇ 求导后搜索最大导数位置
- ◇ Canny 将两者结合在一个操作里

$$(G \otimes I)' = G' \otimes I$$



$$G_{\sigma}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

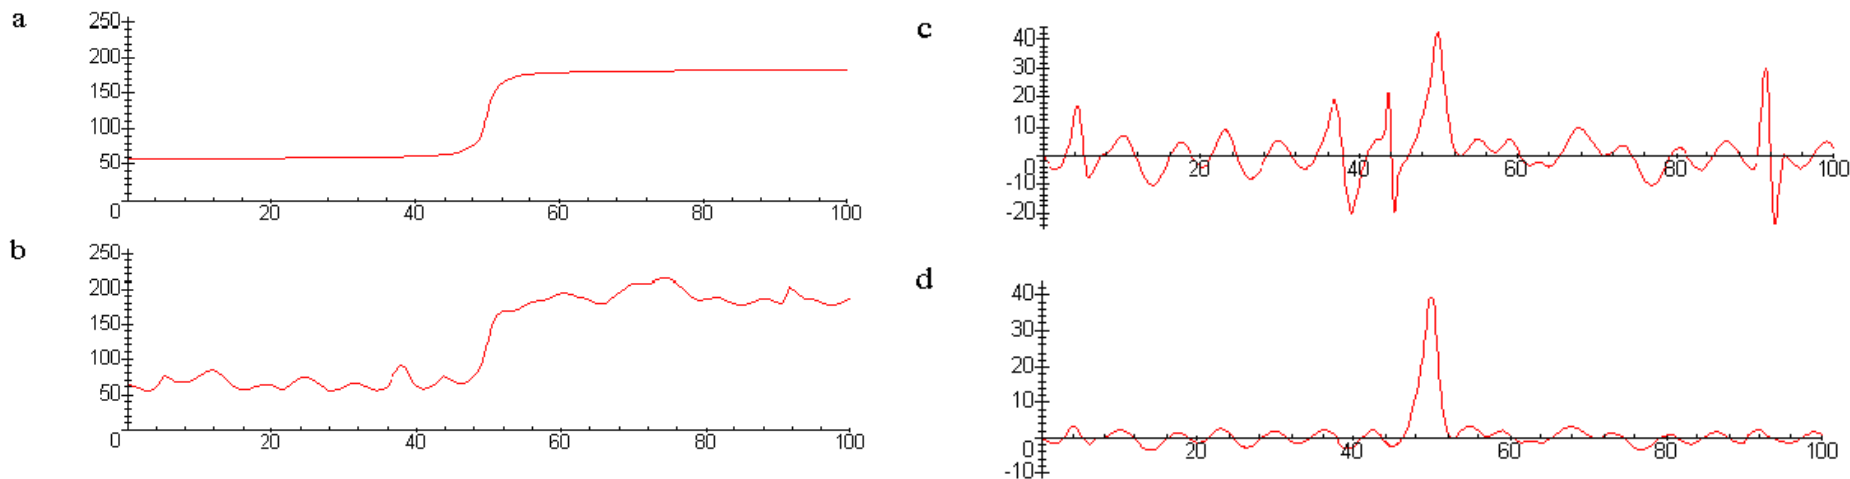


$$G'_{\sigma}(x) = \frac{-x}{\sqrt{2\pi}\sigma^3} e^{-\frac{x^2}{2\sigma^2}}$$

(a) A Gaussian function. (b) The first derivative of a Gaussian function.



边缘检测: Canny 1D 例子



- (a) 一个理想台阶边缘的强度 1-D 分布图。
- (b) 实际边缘的强度分布图 $I(x)$ 。
- (c) 直接求导后, $I'(x)$ 。
- (d) 求卷积: $R(x) = G' \otimes I$, 其中 G' 是一个高斯函数的一阶导数。(相当于先平滑再求导)




边缘检测: Canny


◇ 1-D 边缘检测可以表示为下列步骤:

1. 计算图像 I 与 G' 的卷积, 得到 R
2. 对 R 取绝对值
3. 对那些超过事先定义的阈值 T 的 $|R|$ 的局部极值做标记, 选择阈值去除因噪声产生的伪极值。


◇ 2D \rightarrow 二维高斯函数



$$G_{\sigma}(x, y) = G_{\sigma}(x)G_{\sigma}(y)$$



$$f_V(x, y) = G'_{\sigma}(x)G_{\sigma}(y)$$




$$f_H(x, y) = G'_{\sigma}(y)G_{\sigma}(x)$$



边缘检测: Canny 例子

- a) Canny 边缘检测的例子
- b) 非最大压缩后





梯度边缘检测器

◆ Roberts

$$|G| \cong \sqrt{r_1^2 + r_2^2} ; \quad r_1 = \begin{bmatrix} -1 & 0 \\ 0 & 1 \end{bmatrix} ; \quad r_2 = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

◆ Prewitt

$$|G| \cong \sqrt{p_1^2 + p_2^2} ; \quad \theta \cong \text{atan}\left(\frac{p_1}{p_2}\right) ; \quad p_1 = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix} ; \quad p_2 = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 0 & 1 \\ -1 & 0 & 1 \end{bmatrix}$$

◆ Sobel

$$|G| \cong \sqrt{s_1^2 + s_2^2} ; \quad \theta \cong \text{atan}\left(\frac{s_1}{s_2}\right) ; \quad s_1 = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{bmatrix} ; \quad s_2 = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$



例子


a) 原始图像




b) 滤波后
(Sobel)



c) 加阈值





d) 非最大抑制





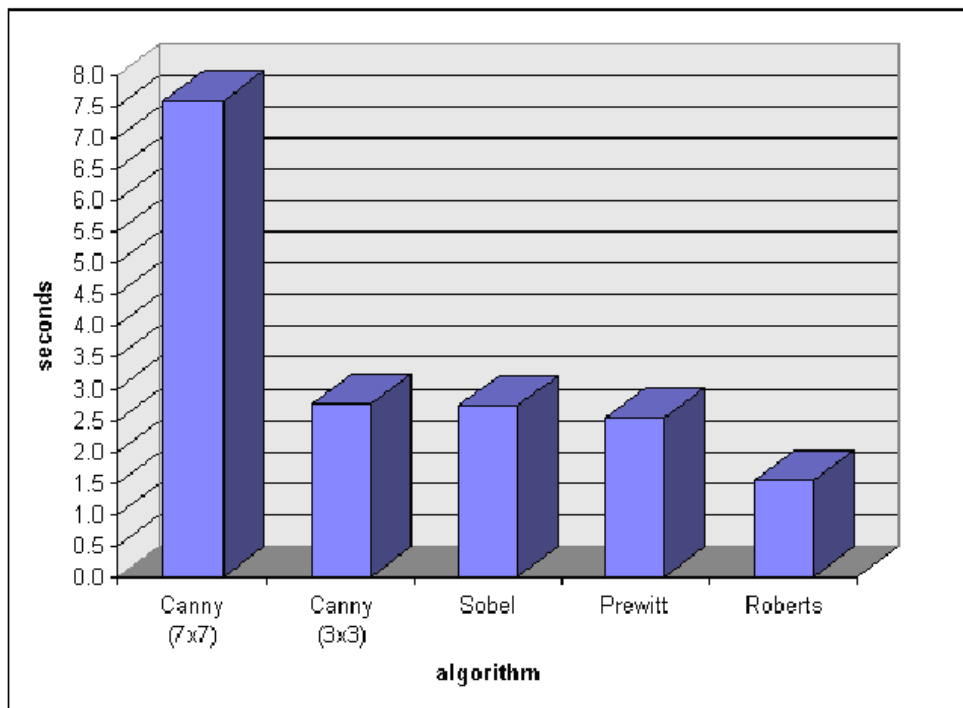
非最大抑制

- 通常，边缘检测器的输出是一幅黑白图像，其中，梯度绝对值大于预定阈值的像素黑色，其余白色。
- 非最大压缩产生单像素宽度的轮廓





边缘检测方法的比较





- ◇ 计算780 x 560 像素图像的边缘图所需的平均时间。
- ◇ 计算一幅边缘图像所需时间，与边缘图像的精度成正比。



动态设定阈值


- ◇ 光照改变
 - ◇ 定常阈值在边缘检测中不适用
- ◇ 对阈值动态自适应
 - ◇ 只考虑 n 个具有最高梯度绝对值的像素，对进一步的计算。
(梯度阈值选为绝对值第 n 大的梯度的值。)





(a) 图像中具有特定梯度值的像素数目；(b) 与 (a) 一样，但用对数标度



分组，聚类：将特征分配给特征



◇ 相连成分的标记





霍夫变换：直线边缘提取

- ◆ 在一条直线边缘上的所有点 p 必须满足关系式： $y_p = m_1 x_p + b_1$ 。
- ◆ 该线上的各点 (x_p, y_p) 对参数 m_1 和 b_1 产生约束。
- ◆ 霍夫变换找到的直线（实际上是直线参数 m, b ）使从图像中边缘像素得到的“投票”最多。
- ◆ 由以下四个步骤实现
 1. 产生一个 2D 阵列 $A[m, b]$ ， A 具有 m 和 b 棋盘格化的轴。
 2. 阵列 A 初始化为 0。
 3. 对图像中各边缘像素 (x_p, y_p) ，对所有 m 和 b 的值循环计算：
如果 $y_p = m_1 x_p + b_1$ ，则 $A[m, b] += 1$
 4. 在阵列 A 中搜索值最大的元素，它们对应了图像中要提取的直线边缘。



不确定性的表示

◇ 感觉，总是与不确定性有关。

◇ 不确定性的来源是什么？

◇ 如何描述和量化不确定性？

◇ 它们如何传播—一个不确定数值的函数的不确定性？

◇ 如融合不同传感器的读数时，不确定性是如何结合的？

◇ 对于移动机器人，所有这些的价值是什么？

◇ 一些定义：

◇ 灵敏度：

$G = \text{输出} / \text{输入}$

◇ 分辨率：

能够检测的最小变化

◇ 动态范围：


最大值 / 分辨率 ($10^4 - 10^6$)

◇ 精确性：

最大误差 = (测量值) - (真实值)

◇ 误差通常是未知的：

确定性的




非确定性的 (随机的)



不确定性的表示 (2)

◇ 统计的表示，随机变量的独立性






高斯分布 (Gaussian)

$$\mu = 0 \text{ and } \sigma = 1$$


$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$






误差传播规律：激励

- ◆ 设想，从带有不确定性的点测量结果中提取一条直线。
- ◆ 模型参数 r (垂线长度) 和 α (垂线与横坐标之间夹角) 唯一地描述一条直线



- ◆ 问题：

- ◆ 当已知测量点的不确定性，所提取直线的不确定性是什么？



误差传播规律



◆ 在 n 个输入 m 个输出的 MIMO 系统中，误差的传播

$$Y_j = f_j(X_1, X_2, \dots, X_n)$$



误差传播规律

◆ 非线性误差传播问题的一维例子

◆ 输出协方差矩

阵 C_Y 由以下误差传播律

给出:


$$C_Y = F_X C_X F_X^T$$

◆ 其中,

- ◆ C_X : 表示输入不确定性的协方差矩阵
- ◆ C_Y : 表示传播到输出的不确定性的协方差矩阵
- ◆ F_X : 是雅可比矩阵, 定义如下:

$$F_X = \nabla f = \left[\nabla_X \cdot f(X) \right]^T = \begin{bmatrix} f_1 \\ \vdots \\ f_m \end{bmatrix} \begin{bmatrix} \frac{\partial}{\partial X_1} & \cdots & \frac{\partial}{\partial X_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial X_1} & \cdots & \frac{\partial f_1}{\partial X_n} \\ \vdots & \cdots & \vdots \\ \frac{\partial f_m}{\partial X_1} & \cdots & \frac{\partial f_m}{\partial X_n} \end{bmatrix}$$

◆ 这是 $f(X)$ 的梯度阵的转置。






基于测距数据的特征：直线提取 (1)

$$\rho_i \cos(\theta_i - \alpha) - r = d_i$$

◇ 最小二乘

$$S = \sum_i d_i^2 = \sum_i (\rho_i \cos(\theta_i - \alpha) - r)^2$$

$$\frac{\partial S}{\partial \alpha} = 0 \quad \frac{\partial S}{\partial r} = 0$$



◇ 加权最小二乘

$$w_i = 1/\sigma_i^2$$

$$S = \sum w_i d_i^2 = \sum w_i (\rho_i \cos(\theta_i - \alpha) - r)^2$$



基于测距数据的特征：直线提取 (2)

◇ 17 组测量


◇ 误差 (σ) 与 ρ^2 正比

◇ 加权最小二乘:

$$w_i = 1/\sigma_i^2$$

$$\alpha = \frac{1}{2} \text{atan} \left(\frac{\sum w_i \rho_i^2 \sin 2\theta_i - \frac{2}{\sum w_i} \sum \sum w_i w_j \rho_i \rho_j \cos \theta_i \sin \theta_j}{\sum w_i \rho_i^2 \cos 2\theta_i - \frac{1}{\sum w_i} \sum \sum w_i w_j \rho_i \rho_j \cos(\theta_i + \theta_j)} \right)$$

$$r = \frac{\sum w_i \rho_i \cos(\theta_i - \alpha)}{\sum w_i}$$





直线提取过程中，不确定性的传播

$$C_{AR} = \begin{bmatrix} \sigma_A^2 & \sigma_{AR} \\ \sigma_{AR} & \sigma_R^2 \end{bmatrix} \quad ? \quad (\text{输出协方差矩阵})$$

$$C_X = \begin{bmatrix} C_P & \mathbf{0} \\ \mathbf{0} & C_Q \end{bmatrix} = \begin{bmatrix} \text{diag}(\sigma_{\rho_i}^2) & \mathbf{0} \\ \mathbf{0} & \text{diag}(\sigma_{\theta_i}^2) \end{bmatrix} \quad 2n \times 2n$$

雅可比矩阵 (Jacobian) :

$$F_{PQ} = \begin{bmatrix} \frac{\partial \alpha}{\partial P_1} & \frac{\partial \alpha}{\partial P_2} & \cdots & \frac{\partial \alpha}{\partial P_n} & \frac{\partial \alpha}{\partial Q_1} & \frac{\partial \alpha}{\partial Q_2} & \cdots & \frac{\partial \alpha}{\partial Q_n} \\ \frac{\partial r}{\partial P_1} & \frac{\partial r}{\partial P_2} & \cdots & \frac{\partial r}{\partial P_n} & \frac{\partial r}{\partial Q_1} & \frac{\partial r}{\partial Q_2} & \cdots & \frac{\partial r}{\partial Q_n} \end{bmatrix}$$

$$C_{AR} = F_{PQ} C_X F_{PQ}^T \quad \begin{array}{l} P_i : \rho_i \\ Q_i : \theta_i \end{array}$$


$$\alpha = \frac{1}{2} \text{atan} \left(\frac{\sum w_i \rho_i^2 \sin 2\theta_i - \frac{2}{\sum w_i} \sum \sum w_i w_j \rho_i \rho_j \cos \theta_i \sin \theta_j}{\sum w_i \rho_i^2 \cos 2\theta_i - \frac{1}{\sum w_i} \sum \sum w_i w_j \rho_i \rho_j \cos(\theta_i + \theta_j)} \right)$$

$$r = \frac{\sum w_i \rho_i \cos(\theta_i - \alpha)}{\sum w_i}$$



线提取中的分割


a) Image Space



A set of n_f neighboring points
of the image space

$$(x_j - \bar{x})^T (x_j - \bar{x}) \leq d_m$$

b) Model Space






Evidence accumulation in the model space
→ Clusters of normally distributed vectors

图4.36 聚类：寻找公共直线的相邻段




角度直方图 (range)



机器人根据自身方向，以及相邻两次测得的距离差确定对象在世界坐标系下的角度



提取其它几何特征



拐角特征—具有方向的点特征



平面图提取（=地面上物体的提取，或背景提取）

◇ 基于视觉的通道辨认

◇ 处理步骤

◇ 作为预处理，使用高斯平滑算子对 I_f 平滑

◇ 对具有 n 个强度值的直方图阵列 H 初始化: $H[i] = 0$ for $i = 1, \dots, n$

◇ 对每一个在 I_f 中的像素 (x,y) ，递增直方图:

$$H[I_f(x, y)] += 1$$



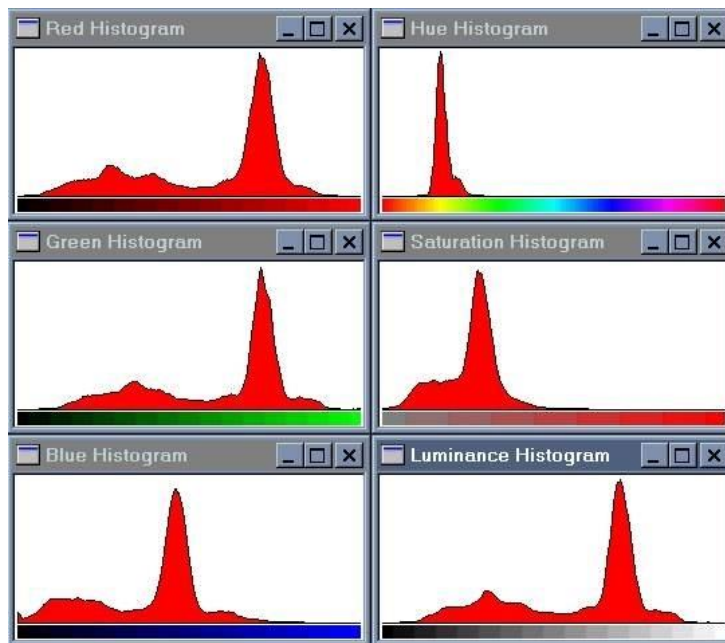


图像直方图

◇ 处理步骤

- ◇ 作为预处理，用高斯平滑算子，平滑图像。
- ◇ 对具有 n 级的 H_i 初始化: $H[j] = 0$ for $j = 1, \dots, n$
- ◇ 对每一个在 G_i 中的像素 (x,y) ，递增直方图: $H_i[G_i[x,y]] += 1$

◇ r,g,b,色调,
饱和度, 亮度





图像直方图

- ◆ 多个直方图联合表示一个特征向量;
- ◆ 将比较两个图像的相似程度, 化为比较两个特征向量的相似程度;
- ◆ 有许多种相似度量方法, 如教材中列出的: J氏散度 $d(H,K)$ 等。



图像指纹提取

◇ 简单特征的高度可分辨结合



局部特征：垂直边缘和16个离散色调

基因序列？

Place x: vvBEvvCvvvMvOBvvvvv



Place 1: vvBEvMvCvvvMvMOBvvvv




Place 2: LvLvLvBvvOLvBEvOvvv





全景图像特征

◇ 全向摄像





西安交通大学
Xi'an Jiaotong University

*Systems Engineering Institute,
Xi'an Jiaotong University,
Xi'an ShaanXi,
710049, P.R.China
Phone: 86-29-82667771*

The End